Academia de Studii Economice din București

Facultatea de Cibernetică, Statistică și Informatică Economică
Specializarea: Cibernetică economică

LUCRARE DE LICENȚĂ

Profesor coordonator:

Conf. Univ. Dr. Zamfir Ionela Cătălina

Student:

Boicu Tudor-Adrian

București

2026

Academia de Studii Economice din București

Facultatea de Cibernetică, Statistică și Informatică Economică
Specializarea: Cibernetică economică



Analiza și previziunea consumului electric în țările europene

Profesor coordonator:

Conf. Univ. Dr. Zamfir Ionela Cătălina

Student:

Boicu Tudor-Adrian

București

2026

CUPRINS

INTRODUCERE **7**
OBIECTIVELE LUCRĂRII **8**
CAPITOLUL 1. STADIUL CUNOAȘTERII ÎN DOMENIU **9**
1.1. Recenzia literaturii de specialitate 9
1.1.1. Modelarea și prognoza consumului de electricitate prin serii de timp 10
1.1.2. Relația dintre consumul de electricitate și activitatea economică și industrială 11
1.1.3. Abordări de cointegrare prin modele ARDL și testarea bounds 12
1.1.4. Modele vectoriale autoregresive și modele cu corecția erorii în domeniul energetic 13
1.1.5. Determinanții climatici ai consumului de electricitate 14
1.1.6. Impactul șocurilor exogene asupra consumului de electricitate 15
1.1.7. Contribuția prezentei lucrări în raport cu literatura existentă 15
CAPITOLUL 2. METODOLOGIA CERCETĂRII **17**
2.1. Sursele de date și variabilele analizate 17
2.2. Analiza univariată a seriilor de timp 17
2.3. Analiza multivariată 22
CAPITOLUL 3. STUDIUL DE CAZ **27**
3.2. Analiza univariată: prezentarea rezultatelor 29
3.2.1. Transformarea Box-Cox și staționarizarea 29
3.2.2. Identificarea modelelor SARIMA specificate propriu 34
3.2.3. Compararea modelelor și selecția modelului final 35
3.2.4. Context economic și interpretarea profilurilor de consum 39
3.3. Analiza multivariată: prezentarea rezultatelor 43
3.3.1. Existența relației de termen lung 44
3.3.2. Termenul de corecție și tensiunea reversiune–cointegrare 46
3.3.3. Semnul producției industriale în relația de echilibru 46
3.3.4. Diagnosticarea modelelor 47
3.3.5. Performanța predictivă out-of-sample 48
3.4. Sinteză 48
CONCLUZII **52**
BIBLIOGRAFIE **54**

LISTA FIGURILOR

Figura 3.1. Evoluția consumului de energie electrică pentru țările europene 27
Figura 3.2. Evoluția indicelui de producție industrială pentru țările europene 28
Figura 3.3. Evoluția gradelor-zile termice pentru țările europene 29
Figura 3.4. Modelul de prognoză optim pe țări 38
Figura 3.5. Evoluția previzionată a consumului electric în anii 2026-2027 pentru țările europene 39
Figura 3.6. Modelul ARDL pe țări: relația consum-producție-climă, 2008-2025 45

LISTA TABELELOR

Tabelul nr. 3.1. Transformarea Box-Cox și specificarea modelelor SARIMA pe țări 29

Tabelul nr. 3.2. Compararea acurateței modelelor SARIMA proprii, automate și ETS, in-sample, pe țări 35

Tabelul nr. 3.3. Specifi cațiile modelelor, acuratețea și modelul final selectat, pe țări ...36

Tabelul nr. 3.4. Contextul economic și interpretarea profilurilor de consum, pe țări 39

Tabelul nr. 3.5. Rezultatele estimării ARDL: testul bounds, verdictul relației de termen lung, termenul de corecție și multiplicatorii, pe țări 44

Tabelul nr. 3.6. Diagnozele reziduurilor, stabilitatea CUSUM și performanța predictivă out-of-sample, pe țări.....47

Tabelul nr. 3.7. Sinteza interpretativă a relației de termen lung, pe țări.....48

INTRODUCERE

Consumul de energie electrică urmărește îndeaproape evoluția oricărei economii moderne. Electricitatea alimentează industria, transportul, serviciile și locuințele, iar evoluția cererii sale reflectă simultan ritmul activității productive, nivelul de trai al populației și condițiile climatice ale regiunii. Tocmai de aceea, modelarea și previziunea consumului de energie electrică nu sunt exerciții pur tehnice, ci au implicații directe pentru planificarea infrastructurii energetice, pentru orientarea politicilor de tranziție și pentru menținerea echilibrului piețelor europene de electricitate.

Interesul pentru acest domeniu a crescut odată cu succesiunea de șocuri care au marcat ultimele două decenii. Criza financiară din 2008 a restructurat cererea industrială, pandemia de COVID-19 a produs contracții abrupte urmate de reveniri neobișnuit de rapide, iar criza energetică europeană din 2021 a expus vulnerabilitățile structurale ale sistemelor de aprovizionare. Fiecare dintre aceste evenimente a lăsat urme vizibile în seriile de consum, complicând modelarea și subliniind nevoia unor instrumente analitice capabile să opereze în condiții de instabilitate.

Prezenta lucrare analizează consumul de energie electrică în 26 de state europene, pe baza datelor lunare extrase din baza de date Eurostat pentru perioada 2008-2025. Analiza urmărește două direcții complementare. Prima, de natură univariată, vizează modelarea și previziunea fiecărei serii naționale de consum, prin punerea în competiție a modelelor SARIMA construite individual, a celor selectate automat și a modelelor de netezire exponențială. A doua, de natură multivariată, investighează relațiile dinamice dintre consumul de electricitate, indicele producției industriale și gradele-zile termice, prin clasa modelelor autoregresive cu întârzieri distribuite.

Față de studiile care tratează o singură țară sau care se limitează la date anuale, lucrarea adoptă o perspectivă comparativă pe un eșantion amplu de economii europene, urmărind atât descrierea tiparelor naționale, cât și identificarea regularităților comune și a diferențelor structurale dintre ele.

OBIECTIVELE LUCRĂRII

Obiectivul general al lucrării este analiza și previziunea consumului de energie electrică în 26 de state europene, în perioada 2008-2025, pe două direcții metodologice complementare, urmărind atât caracterizarea individuală a fiecărei economii, cât și identificarea regularităților transversale și a eterogenității structurale dintre țări.

Pentru atingerea acestui obiectiv general au fost formulate următoarele obiective specifice:

1. Modelarea și previziunea fiecărei serii naționale de consum prin metodologia Box-Jenkins, prin compararea modelelor SARIMA specificate propriu cu modele selectate automat și cu modele de netezire exponențială, evaluate pe baza performanței predictive în afara eșantionului de estimare.
2. Investigarea existenței unei relații de echilibru pe termen lung între consumul de electricitate, producția industrială și stresul termic, prin modele autoregresive cu întârzieri distribuite și prin testul bounds.
3. Estimarea dinamicii pe termen scurt și a termenului de corecție a erorii pentru fiecare economie analizată.
4. Examinarea direcției legăturilor dintre variabile, prin testul de cauzalitate Granger, și verificarea robustețeі modelelor prin teste de diagnosticare a reziduurilor și de stabilitate a coeficienților.
5. Identificarea regularităților comune și a diferențelor structurale dintre cele 26 de economii europene și interpretarea lor economică.

Întregul demers a fost conceput astfel încât să respecte rigoarea metodologică specifică analizei seriilor de timp și econometriei, să se bazeze exclusiv pe date și surse disponibile în acces liber și să poată fi reprodus integral în mediul R.

CAPITOLUL 1. STADIUL CUNOAȘTERII ÎN DOMENIU

1.1. Recenzia literaturii de specialitate

Consumul de energie electrică și prognoza acestuia constituie un domeniu de cercetare cu implicații practice directe pentru planificarea rețelelor, formularea politicilor energetice și gestionarea echilibrului dintre cerere și ofertă pe piețele europene. Literatura de specialitate din ultimul deceniu s-a dezvoltat pe două direcții metodologice care se regăsesc și în structura prezentei lucrări. Prima direcție vizează modelarea și prognoza seriilor individuale de consum prin metode de tip serii de timp, de la modelele clasice Box-Jenkins (ARIMA și extensia lor sezonieră SARIMA) și netezirea exponențială (ETS) până la metode moderne de învățare automată. A doua direcție investighează relațiile dinamice dintre consumul de electricitate, activitatea economică și condițiile climatice, recurgând la instrumente econometrice precum modelele ARDL, modelele vectoriale autoregresive (VAR) și modelele vectoriale cu corecția erorii (VECM).

Prezenta lucrare de licență are ca obiectiv analiza consumului de energie electrică în 26 de state europene pe perioada 2008-2025, urmărind ambele direcții menționate. Componenta univariată constă în modelarea și prognoza seriilor individuale de consum prin SARIMA, prin modele selectate automat după criteriul AIC și prin modele ETS, evaluate comparativ pe baza unor metrici de performanță predictivă calculate în afara eșantionului de estimare (RMSE, MAPE, MASE). Componenta multivariată investighează relațiile dintre consumul lunar de electricitate (Elec, în GWh), indicele producției industriale (IPI) și gradele-zile termice (TDD, o măsură agregată a stresului termic care cumulează cererea de încălzire și de climatizare), utilizând clasa modelelor ARDL. Toate seriile provin din baza de date Eurostat, iar studiul vizează nu doar descrierea tiparelor naționale, ci și identificarea unor regularități transversale comune și a eterogenității structurale dintre economiile europene în privința determinanților consumului energetic.

Secțiunea de față analizează principalele contribuții academice recente, publicate în ultimii opt ani, relevante pentru tema, metodologia și obiectivele lucrării. Lucrările sunt grupate tematic pentru a evidenția modul în care se articulează cu demersul cercetării de față, pornind de la studiile de prognoză prin serii de timp, continuând cu cele dedicate relației dintre consumul electric și activitatea industrială, cu abordările de cointegrare de tip ARDL, VAR și VECM, și încheind cu literatura privind determinanții climatici și impactul șocurilor exogene. Toate referințele citate sunt disponibile integral în regim de acces liber.

1.1.1. Modelarea și prognoza consumului de electricitate prin serii de timp

Pełka (2023) propune în revista Energies o metodologie de prognoză a consumului lunar de electricitate construită pe ideea reprezentării ciclului anual sub forma unui tipar standardizat, aplicată unui set de date pentru 35 de țări europene preluate din platforma ENTSO-E. Autorul pornește de la constatarea că seriile lunare de consum electric prezintă, în formularea sa, „cicluri de variație sezonieră, tendințe pe termen lung, episoade de instabilitate și o componentă reziduală aleatoare.”, elemente care complică prognoza directă. Prin codificarea fiecărui an într-un tipar care filtrează tendința, problema de predicție este simplificată considerabil. Sunt testate trei metode statistice clasice, respectiv ARIMA, netezirea exponențială ETS și Prophet, în variantele cu și fără această preprocesare, iar rezultatele arată o îmbunătățire a acurateței de 13,7 până la 25 la sută, măsurată prin eroarea procentuală absolută medie. Studiul compară aceste metode cu modele de învățare automată și constată că abordările statistice rămân competitive pe orizonturi medii de prognoză. Lucrarea este direct relevantă pentru componenta univariată a prezentei cercetări, deoarece operează la același nivel de agregare temporală, în același spațiu geografic european și cu metode parțial suprapuse, respectiv ARIMA și ETS.

Şahin, Ballı și Chen (2021) analizează în Applied Energy modul în care restricțiile impuse în contextul pandemiei COVID-19 au afectat generarea de electricitate în cinci țări europene, respectiv Franța, Germania, Spania, Turcia și Regatul Unit, utilizând date lunare pentru perioada cuprinsă între ianuarie 2017 și septembrie 2020. Autorii compară previziuni obținute prin patru modele sezoniere de tip grey, incluzând un model fracțional optimizat printr-un algoritm genetic, cu trei metode de învățare automată. Rezultatele arată că generarea din surse neregenerabile a scăzut cu 21 până la 25 la sută în trimestrul al doilea din 2020, comparativ cu aceeași perioadă din 2019, în Franța, Germania, Spania și Regatul Unit. Studiul este relevant pentru prezenta lucrare prin acoperirea geografică europeană, prin frecvența lunară a datelor și prin demonstrarea faptului că șocurile exogene majore, precum pandemia, trebuie luate în considerare la modelarea seriilor de consum și de generare a energiei electrice.

Bashiri Behmiri, Fezzi și Ravazzolo (2023) abordează în revista Energy una dintre cele mai discutate probleme metodologice ale prognozei consumului electric pe termen mediu, anume tratamentul variabilelor meteorologice. Autorii realizează o comparație sistematică a trei abordări, respectiv excluderea temperaturii din model, asumarea cunoașterii perfecte a temperaturii viitoare și utilizarea prognozelor meteorologice reale, evaluând impactul fiecărei opțiuni asupra acurateței prognozei. Sunt testate atât regresii de serii de timp, cât și rețele neurale, pe date din mai multe piețe europene. Concluzia centrală este că modelele care includ temperatura viitoare depășesc semnificativ performanța celor care o exclud, la toate orizonturile

de prognoză, însă îmbunătățirea se atenuează atunci când temperatura reală este înlocuită cu prognoza sa, din cauza erorilor crescânde ale prognozelor meteorologice. Această constatare confirmă, pentru prezenta lucrare, relevanța includerii variabilelor termice de tipul gradelor-zile în analiza relației dintre consum și climat. (Bashiri Behmiri et al., 2023)

Bianco, Marchitto, Scarpa și Tagliafico (2020) propun în International Journal of Environmental Research and Public Health o metodologie de prognoză a cererii rezidențiale de energie în patru țări europene, respectiv Germania, Italia, Spania și Lituania. Consumul este modelat ca funcție de gradele-zile de încălzire și de produsul intern brut pe cap de locuitor, prin intermediul unei relații dinamice. Analiza elasticităților relevă diferențe importante între țări, Germania prezentând o elasticitate negativă a consumului față de venit, interpretată prin câștigurile ridicate de eficiență energetică, în timp ce Italia și Spania prezintă elasticități pozitive. Prognozele arată că Germania și Italia sunt mai sensibile la variațiile climatice decât Spania, cu creșteri de consum de 8 până la 9 la sută în scenarii de temperaturi scăzute. Trei dintre cele patru țări analizate fac parte și din eșantionul prezentei lucrări, iar utilizarea explicită a gradelor-zile ca variabilă determinantă oferă un precedent metodologic pentru includerea variabilei TDD în componenta multivariată.

1.1.2. Relația dintre consumul de electricitate și activitatea economică și industrială

Fezzi și Fanghella (2021) dezvoltă în European Economic Review o metodologie pentru urmărirea în timp real a impactului șocurilor economice asupra produsului intern brut, pornind de la legătura empirică stabilă dintre consumul de electricitate și activitatea economică. Premisa metodologică se bazează pe faptul că electricitatea este consumată în aproape toate procesele productive, ceea ce face din ea un indicator avansat al activității economice generale. Autorii aplică metodologia pentru 12 țări europene în primul val al pandemiei și obțin estimări ale pierderilor de produs intern brut pe care le descriu drept „*rezultate aproape imposibil de deosebit de cele oficiale*.”, pentru primele două trimestre din 2020. Contribuția acestei lucrări la fundamentarea prezentei cercetări este esențială, deoarece confirmă legătura strânsă dintre consumul electric și activitatea industrială, legătură care justifică utilizarea indicelui producției industriale ca variabilă explicativă în componenta multivariată a lucrării.

Sankaran, Kumar, Arjun și Das (2019) investighează în revista Heliyon relația cauzală dintre consumul de electricitate și producția industrială manufacturieră, utilizând date anuale pentru perioada 1980-2016 pentru zece țări recent industrializate. Studiul aplică abordarea de tip bounds testing din clasa modelelor ARDL, descrisă de autori ca fiind aplicată „*pentru estimarea legăturii pe termen lung dintre variabile*.”, recurgând la un model cu corecția erorii pentru

dinamica pe termen scurt și la testul de cauzalitate Toda-Yamamoto pentru a stabili direcția relației. Rezultatele confirmă existența unei relații pe termen scurt și pe termen lung între variabile, iar testele de cauzalitate susțin, în funcție de țară, ipotezele de creștere, de conservare, de retroacțiune și de neutralitate. Această lucrare prezintă o relevanță deosebită pentru prezenta cercetare, deoarece tratează exact relația centrală a componentei multivariate, respectiv legătura dintre consumul de electricitate și producția industrială, prin aceleași instrumente econometrice, ARDL, bounds testing și termen de corecție a erorii.

1.1.3. Abordări de cointegrare prin modele ARDL și testarea bounds

Marinaș, Dinu, Socol și Socol (2018), cercetători ai Academiei de Studii Economice din București, examinează în revista PLOS ONE relația dintre creșterea economică și consumul de energie din surse regenerabile în zece state membre ale Uniunii Europene din Europa Centrală și de Est, printre care România, pe perioada 1990-2014. Studiul recurge la procedura de modelare ARDL, o tehnică ce surprinde atât relațiile pe termen scurt, cât și pe cele pe termen lung dintre variabile. Autorii pornesc de la premisa că noul model european vizează realizarea unei creșteri economice de tip „o creștere economică incluzivă, durabilă și inteligentă", în care sporirea ponderii energiei regenerabile joacă un rol important. Rezultatele arată că, pe termen scurt, dinamica produsului intern brut și cea a consumului de energie regenerabilă sunt independente în România și Bulgaria, în timp ce în Ungaria, Lituania și Slovenia o creștere a consumului regenerabil stimulează creșterea economică. Ipoteza cauzalității bidirecționale între consumul de energie regenerabilă și creșterea economică este validată pe termen lung pentru întregul grup analizat. Lucrarea oferă un model metodologic apropiat de cel al prezentei cercetări, fiind totodată un reper relevant prin includerea României și prin proveniența autorilor din aceeași instituție academică.

Litavcová și Chovancová (2021) analizează în revista Energies relațiile de cointegrare, dinamica pe termen lung și scurt și relațiile de cauzalitate dintre emisiile de dioxid de carbon, consumul de energie și creșterea economică în 14 țări din regiunea Dunării, pe perioada 1990-2019. Autoarele aplică metodologia de tip bounds testing din clasa modelelor ARDL, tratând pe rând fiecare variabilă ca variabilă dependentă, și obțin rezultate valide pentru 26 dintre cele 36 de modele ARDL estimate. Testarea bounds a confirmat în mod robust existența unei relații de echilibru pe termen lung între emisii, consumul de energie și creșterea economică în Austria, Cehia, Slovacia și Slovenia. Studiul este relevant pentru prezenta lucrare prin acoperirea geografică, care include numeroase state din Europa Centrală și de Est prezente și în eșantionul analizat, și prin aplicarea sistematică a procedurii bounds testing pe un set de țări europene, exact instrumentul utilizat în componenta multivariată.

Pavlova, Pavlov, Liashenko, Jamróz și Kopeć (2025) investighează în revista Energies determinanții pe termen scurt și lung ai consumului de gaze naturale în Uniunea Europeană, utilizând o abordare de tip bounds testing din clasa modelelor ARDL, cu produsul intern brut pe cap de locuitor și consumul de combustibili lichizi și solizi ca variabile explicative. Lucrarea prezintă o valoare metodologică deosebită pentru prezenta cercetare, deoarece testele Augmented Dickey-Fuller confirmă, în formularea autorilor, „*ordine de integrare eterogene, care fac posibilă o estimare ARDL validă*", situație care justifică tocmai alegerea modelelor ARDL, identică cu raționamentul metodologic al lucrării de față. Rezultatele relevă o relație de echilibru pe termen lung statistic semnificativă, iar un model cu corecția erorii confirmă o convergență rapidă către echilibru, cu 77 la sută dintre abateri corectate într-o singură perioadă. Testele recursive de tip CUSUM indică stabilitate structurală în timp, aceleași instrumente de diagnosticare a stabilității coeficienților fiind utilizate și în prezenta lucrare.

1.1.4. Modele vectoriale autoregresive și modele cu corecția erorii în domeniul energetic

Marra și Colantonio (2022) studiază în Journal of Industrial and Business Economics determinanții instituționali și socio-tehnici ai producției de energie regenerabilă în 18 state membre ale Uniunii Europene, pe perioada 1990-2015, recurgând la un model vectorial autoregresiv pe date panel. Variabilele incluse în sistemul dinamic sunt producția de energie regenerabilă, rigoarea politicii de mediu, gradul de conștientizare publică, activitatea de lobby și nivelul de educație, controlându-se pentru venit și pentru importurile de energie. Rezultatele arată o eterogenitate puternică între state, statele membre angajându-se în tranziția energetică în ritmuri diferite, în funcție de punctul de plecare al fiecăruia. Lucrarea este relevantă pentru prezenta cercetare ca exemplu de aplicare a metodologiei vectoriale autoregresive în contextul energetic european, una dintre abordările multivariate luate în considerare în cadrul lucrării de față alături de modelele ARDL și VECM.

Stanciu și Mitu (2025), cercetători ai Universității din Craiova, examinează în revista Energies integrarea și comportamentul prețurilor pe piețele de electricitate din Uniunea Europeană, recurgând la un model vectorial cu corecția erorii. Studiul utilizează prețuri zilnice angro pentru ziua următoare din 24 de state ale Uniunii Europene, pe perioada cuprinsă între octombrie 2017 și septembrie 2024, și identifică, în formularea autorilor, „apte grupări regionale de piețe, conturate pe baza asemănărilor în evoluția prețurilor". Analiza relevă relații puternice de echilibru pe termen lung și ajustări dinamice pe termen scurt, evidențiind interconectarea piețelor, cu Germania și Franța în rol de poli centrali și cu o grupare distinctă care include România și Bulgaria. Lucrarea este relevantă pentru prezenta cercetare deoarece ilustrează

aplicarea modelului VECM, una dintre abordările vectoriale considerate, într-un context european centrat pe electricitate, fiind totodată un reper metodologic pentru analiza relațiilor de cointegrare dintre serii nestaționare.

Trebuie precizat că alegerea între clasele de modele multivariate, respectiv ARDL, VAR și VECM, depinde în mod direct de proprietățile de staționaritate ale seriilor analizate. Modelele VAR în niveluri presupun serii staționare, în timp ce modelele VECM presupun serii integrate de același ordin și cointegrate. Atunci când seriile prezintă o configurație mixtă, combinând serii staționare în niveluri și serii staționare în prima diferență, fără serii integrate de ordinul al doilea, clasa modelelor ARDL devine cea mai potrivită, motiv pentru care a fost adoptată în componenta multivariată a prezentei lucrări. Discutarea modelelor VAR și VECM rămâne însă necesară, întrucât acestea constituie cadrul de referință din care derivă logica testării bounds și interpretarea termenului de corecție a erorii.

1.1.5. Determinanții climatici ai consumului de electricitate

Pablo-Romero, Sánchez-Braza și González-Jara (2023) analizează în Environmental Science and Pollution Research factorii care influențează consumul de electricitate în Spania la nivel sectorial, utilizând date panel pentru cele 17 comunități autonome pe perioada 2000-2013. Autorii estimează consumul ca funcție de valoarea adăugată brută, de temperaturi cuantificate prin grade-zile de încălzire și de răcire, de capitalizare și de capital uman. Modelul permite separarea efectelor sectoriale, identificând faptul că temperaturile peste 22 de grade Celsius au un efect pozitiv și crescând asupra consumului în sectorul terțiar, în timp ce temperaturile sub 18 grade Celsius au un efect negativ în anumite sectoare. Concluzia centrală, în formularea autorilor, este că „încălzirea globală ar putea duce la creșterea cererii de electricitate în Spania", în special prin nevoi sporite de climatizare. Studiul fundamentează utilizarea variabilelor termice de tipul gradelor-zile, regăsite în prezenta lucrare sub forma variabilei agregate TDD, și confirmă caracterul neliniar al relației dintre temperatură și consum.

Román-Collado, Colinet-Carmona și Fárez-Plasencia (2023) extind analiza consumului de electricitate pe cap de locuitor în Spania printr-o metodologie de descompunere care separă contribuțiile intensității energetice, ale temperaturii, ale structurii economice și ale venitului, publicând rezultatele tot în Environmental Science and Pollution Research. Studiul acoperă perioada 2000-2016 și arată că efectul temperaturii asupra consumului a evoluat în timp, trecând de la un rol predominant inhibitor în intervalul 2000-2008, prin ierni mai blânde, la un rol amplificator în intervalul 2008-2016, pe măsura creșterii frecvenței zilelor cu temperaturi extreme. Autorii subliniază relevanța analizei la nivel regional, deoarece regiunile cu profile climatice diferite prezintă sensibilități distincte. Această constatare susține, pentru prezenta

lucrare, utilizarea unei măsuri agregate a stresului termic care cumulează atât cererea de încălzire, cât și pe cea de răcire, și justifică tratarea separată a celor 26 de țări, cu profile climatice eterogene.

1.1.6. Impactul șocurilor exogene asupra consumului de electricitate

López Prol și O (2020) cuantifică în revista iScience impactul restricțiilor introduse în contextul pandemiei COVID-19 asupra consumului de electricitate pe termen scurt în cele mai afectate țări ale Uniunii Europene și state din Statele Unite. Metodologia se bazează pe un model ipotetic de referință care estimează nivelul consumului în absența restricțiilor, ajustând pentru efectul temperaturii, al zilei din săptămână și al sărbătorilor. Diferența dintre consumul estimat prin acest model și cel observat reprezintă impactul atribuibil restricțiilor. Rezultatele indică o scădere cumulată a consumului de 3 până la 12 la sută în primele cinci luni de la impunerea restricțiilor, cu reduceri deosebit de pronunțate în Italia, Franța, Spania și Germania. Autorii arată totodată că relația dintre severitatea restricțiilor și consum este una neliniară, constatând că „declinul zilnic al consumului de energie elecrică este neliniar". Relevanța acestei lucrări pentru prezenta cercetare constă în atragerea atenției asupra perturbării structurale produse de pandemie în seriile de consum din 2020, perturbare care trebuie tratată cu atenție atât în modelarea univariată, cât și în cea multivariată, pentru a evita erori de prognoză.

Halbrügge, Schott, Weibelzahl, Buhl, Fridgen și Schöpf (2021) analizează în Applied Energy modul în care sistemele electrice din Germania și din alte țări europene au reacționat la pandemia COVID-19, utilizând date orare de cerere, generare și prețuri pentru primul semestru al anului 2020, comparate cu perioadele corespunzătoare din anii precedenți. Rezultatele evidențiază o scădere semnificativă a cererii de electricitate, de circa 10 la sută în Germania în luna aprilie 2020, însoțită de o creștere a ponderii surselor regenerabile în mixul de generare. Autorii analizează totodată efectele asupra prețurilor pe piața pentru ziua următoare și asupra stabilității rețelei, observând o frecvență crescută a prețurilor negative. Studiul completează tabloul impactului pandemiei asupra unor state incluse în eșantionul prezentei lucrări, precum Germania, și întărește necesitatea de a controla perturbările structurale din anul 2020 în cadrul modelelor de serii de timp.

1.1.7. Contribuția prezentei lucrări în raport cu literatura existentă

Recenzia literaturii recente relevă că cercetările existente se grupează în câteva direcții relativ distincte. O primă direcție acoperă prognoza consumului de electricitate prin serii de timp, fie pentru o singură țară, fie pentru un set de țări tratate individual sau prin metode de învățare automată, cu contribuții valoroase pe plan metodologic, dar fără o analiză sistematică,

comparativă, a unui număr mare de state, în care modelele SARIMA, cele selectate automat și cele de tip ETS să fie puse în competiție pe baza performanței predictive în afara eșantionului.

O a doua direcție cuprinde studiile de cointegrare de tip ARDL, VAR și VECM aplicate domeniului energetic. Acestea oferă instrumente robuste pentru identificarea relațiilor de echilibru pe termen lung și a dinamicii pe termen scurt, însă majoritatea operează cu date anuale și se concentrează pe relația dintre energie, creștere economică și emisii, sau pe prețurile electricității, mai degrabă decât pe relația dintre consumul lunar de electricitate, producția industrială și condițiile climatice. Studiile care tratează direct relația dintre consumul electric și producția industrială folosesc, de asemenea, predominant date anuale și eșantioane de țări din afara spațiului european.

O a treia direcție este reprezentată de literatura privind determinanții climatici ai consumului, care confirmă caracterul neliniar al relației dintre temperatură și consum și evoluția în timp a sensibilității la temperaturi extreme, precum și de literatura privind impactul șocurilor exogene, în special pandemia COVID-19, care documentează perturbări structurale importante în seriile de consum.

Prezenta lucrare de licență își propune să reducă acest decalaj printr-o abordare care reunește, pe un set amplu de 26 de state europene și pe date lunare pentru perioada 2008-2025, ambele direcții metodologice. Pe de o parte, componenta univariată realizează o modelare și o prognoză sistematică a fiecărei serii naționale de consum, prin parcurgerea completă a etapelor Box-Jenkins și prin punerea în competiție a modelelor SARIMA specificate propriu, a celor selectate automat după criteriul informațional și a celor de tip ETS, evaluarea finală bazându-se pe metrici de performanță predictivă calculate în afara eșantionului de estimare. Pe de altă parte, componenta multivariată investighează relațiile dinamice dintre consumul de electricitate, indicele producției industriale și gradele-zile termice, prin clasa modelelor ARDL, aleasă în urma constatării unei configurații mixte a ordinelor de integrare a seriilor, configurație incompatibilă atât cu modelele VAR în niveluri, cât și cu modelele VECM.

Originalitatea demersului rezidă în combinarea, pe un eșantion neobișnuit de larg pentru o lucrare de acest nivel, a analizei univariate riguroase, bazate pe competiția dintre modele, cu analiza multivariată a determinanților consumului, precum și în accentul pus pe identificarea regularităților transversale comune și a eterogenității structurale dintre economiile europene. Perioada de analiză, 2008-2025, este suficient de cuprinzătoare pentru a surprinde efectele crizei financiare globale, ale pandemiei COVID-19 și ale crizei energetice europene, oferind astfel un cadru de testare a stabilității relațiilor estimate în condiții de șocuri economice și climatice majore.

CAPITOLUL 2. METODOLOGIA CERCETĂRII

Pornind de la direcțiile de cercetare și de la metodele identificate în literatura de specialitate, capitolul de față descrie fundamentele teoretice ale instrumentarului statistic și econometric pe care se sprijină partea aplicativă a lucrării.

Prezentul subcapitol descrie fundamentele teoretice ale ansamblului de metode statistice și econometrice pe care se sprijină partea aplicativă a lucrării. Analiza consumului de energie electrică a fost organizată pe două direcții complementare. Prima direcție, de natură univariată, a vizat modelarea și previziunea seriei consumului de energie electrică pornind exclusiv de la propria sa evoluție în timp. A doua direcție, de natură multivariată, a urmărit relațiile dintre consumul de energie electrică și doi factori explicativi relevanți, indicele producției industriale și gradele-zile termice.

Datele utilizate au fost extrase din baza de date statistice Eurostat, au frecvență lunară și au fost prelucrate în mediul de programare statistică R. În cele ce urmează sunt prezentate, mai întâi, sursele de date și variabilele analizate, apoi aparatul metodologic al analizei univariate și, în final, aparatul metodologic al analizei multivariate. Pentru fiecare model este indicată forma analitică, iar pentru fiecare test statistic sunt precizate atât statistica de test, cât și ipoteza nulă și alternativă, alături de sursa bibliografică din care informația a fost extrasă.

2.1. Sursele de date și variabilele analizate

Sursa datelor a fost reprezentată de baza de date Eurostat, care pune la dispoziție serii statistice armonizate la nivelul statelor europene. Analiza s-a bazat pe trei variabile observate la frecvență lunară, descrise în continuare.

Caracterul lunar al datelor și prezența unor tipare repetitive cu periodicitate anuală au impus, pe tot parcursul analizei, tratarea explicită a componentei sezoniere, aspect detaliat în secțiunile următoare.

2.2. Analiza univariată a seriilor de timp

O serie de timp este un ansamblu de observații înregistrate succesiv asupra aceluiași fenomen, la intervale egale de timp. În acest sens, Anghelache și Manole (2012, p.68) arată că „seria dinamică / cronologică este formată din două șiruri de date paralele”, primul exprimând variația timpului, iar al doilea variația fenomenului cercetat. Analiza unei astfel de serii pornește de la ideea că valoarea observată la un moment dat poate fi descompusă în câteva componente

care nu se observă direct, o componentă de tendință, care exprimă direcția de evoluție pe termen lung, o componentă sezonieră, care reflectă tiparele repetitive cu periodicitate fixă, și o componentă neregulată, care reunește fluctuațiile fără structură sistematică.

Pentru separarea acestor componente a fost utilizată descompunerea STL (*Seasonal-Trend decomposition using Loess*), pe care Hyndman și Athanasopoulos (2021) o caracterizează drept „*o metodă versatilă și robustă de descompunere a seriilor de timp*". Metoda estimează componentele de tendință și sezonieră prin netezire locală de tip *loess* și, spre deosebire de descompunerile clasice, permite ca tiparul sezonier să se modifice lent în timp, fiind robustă la prezența valorilor extreme, ceea ce o recomandă pentru serii lungi de consum energetic, afectate de șocuri precum criza sanitară sau criza energetică.

Structura de dependență temporală a unei serii a fost examinată cu ajutorul funcției de autocorelație și al funcției de autocorelație parțială. Funcția de autocorelație măsoară corelația dintre observații aflate la o anumită distanță în timp, în timp ce funcția de autocorelație parțială măsoară aceeași corelație după eliminarea efectului perioadelor intermediare. Reprezentate grafic prin corelograme, cele două funcții stau la baza identificării ordinelor unui model autoregresiv și de medie mobilă (Hyndman și Athanasopoulos, 2021) și au fost folosite pentru a citi atât componenta nesezonieră, la primele întârzieri, cât și componenta sezonieră, la întârzierile multiplu de douăsprezece luni.

Atunci când amplitudinea oscilațiilor unei serii crește odată cu nivelul acesteia, varianța nu mai este constantă în timp, ceea ce poate afecta calitatea modelării. Pentru stabilizarea variației a fost considerată transformarea Box-Cox, o familie de transformări de putere guvernată de un parametru care variază între o transformare logaritmică și absența oricărei transformări (Hyndman și Athanasopoulos, 2021). Valoarea parametrului a fost estimată din date, iar transformarea a fost reținută numai atunci când contribuia clar la uniformizarea dispersiei.

Modelarea seriilor de timp presupune, de regulă, staționaritatea acestora. O serie este staționară atunci când media, varianța și structura de autocorelație rămân constante în timp, independent de momentul observării. O serie nestaționară conține adesea o rădăcină unitară, situație în care șocurile au efect permanent, iar nivelul seriei nu revine la o valoare de echilibru. Pentru verificarea staționarității au fost folosite trei teste complementare, prezentate în continuare (Shrestha și Bhatta, 2018).

Testul Augmented Dickey-Fuller se bazează pe estimarea regresiei din relația [1].

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \Sigma_{i=1}^{p} \delta_i \Delta y_{t-i} + \varepsilon_t \quad [1]$$

În această relație, Δ este operatorul de diferențiere, t este componenta de tendință, iar termenii cu Δy întârziat corectează autocorelația erorilor. Ipoteza nulă a testului este existența

unei rădăcini unitare, exprimată prin coeficientul γ egal cu zero, ceea ce indică nestaționaritatea, iar ipoteza alternativă presupune un coeficient γ negativ, deci o serie staționară. Întrucât rezultatul depinde de componentele deterministe incluse, testul a fost aplicat în mai multe variante, cu și fără constantă și tendință (Shrestha și Bhatta, 2018).

Testul KPSS pornește de la ipoteza nulă inversă și folosește statistica din relația [2], construită pe baza sumelor parțiale ale reziduurilor.

$$(1/T^2)\Sigma_{t=1}^{T}(S^2_t/\hat{\sigma}^2), S_t = \Sigma_{i=1}^{t}\hat{e}_i \quad [2]$$

Aici S indică suma parțială a reziduurilor, iar σ pătrat estimat este o estimare a variației pe termen lung. Ipoteza nulă este aceea că seria este staționară în jurul unui nivel sau al unei tendințe deterministe, iar ipoteza alternativă presupune prezența unei rădăcini unitare. Concordanța dintre testul Augmented Dickey-Fuller și testul KPSS oferă o concluzie mai sigură decât utilizarea unui singur test (Shrestha și Bhatta, 2018).

Testul Phillips-Perron pornește de la o regresie similară celei din relația [3], însă corectează în mod neparametric prezența autocorelației și a heteroscedasticității în structura erorilor, fără a introduce termeni de diferențiere întârziați.

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + u_t \quad [3]$$

Ipotezele testului Phillips-Perron coincid cu cele ale testului Augmented Dickey-Fuller, ipoteza nulă fiind existența unei rădăcini unitare, iar cea alternativă, staționaritatea seriei. Corecția se aplică direct statisticii asociate coeficientului γ (Shrestha și Bhatta, 2018).

Numărul de diferențieri necesare pentru a transforma o serie nestaționară într-una staționară definește ordinul de integrare al seriei. O serie staționară în nivel este integrată de ordin zero, o serie care devine staționară după o singură diferențiere este integrată de ordin unu, iar o serie care necesită două diferențieri este integrată de ordin doi. În cazul seriilor lunare cu sezonalitate, diferențierea a fost aplicată pe două planuri, o diferențiere regulată, care înlătură tendința, și o diferențiere sezonieră, care înlătură tiparul repetitiv anual (Hyndman și Athanasopoulos, 2021).

Necesitatea unei diferențieri sezoniere și stabilitatea în timp a tiparului sezonier au fost evaluate cu testul Canova-Hansen, un test de tip multiplicator Lagrange construit pe baza sumelor parțiale ale componentelor sezoniere. Ipoteza nulă a testului este aceea că tiparul sezonier este determinist și stabil în timp, deci staționar, iar ipoteza alternativă presupune existența unei rădăcini unitare sezoniere, asociată unui tipar sezonier care se modifică (Hyndman și Athanasopoulos, 2021).

Pentru a izola evoluția de fond a seriilor de influențele sezoniere, a fost aplicată ajustarea sezonieră, procedeu prin care o serie este descompusă într-o componentă de tendință-ciclu, o

componentă sezonieră și o componentă neregulată (Drăgușin, 2013). Drăgușin (2013, p.11) subliniază că „fluctuațiile sezoniere sunt efecte sistematice, persistente, previzibile și identificabile", ceea ce justifică tratarea lor separată. Descompunerea poate fi aditivă, atunci când amplitudinea componentelor este independentă de nivelul seriei, sau multiplicativă, atunci când oscilațiile sezoniere cresc odată cu nivelul seriei. Ajustarea s-a realizat cu procedura TRAMO-SEATS, care modelează mai întâi seria printr-un model de tip ARIMA, tratând valorile lipsă și valorile aberante, după care extrage componentele neobservabile. Așa cum arată Anghelache, Anghelache și Bârsan (2019, p.3), „problema privind descompunerea seriilor cronologice a fost sintetizată de Eurostat", procedura reprezentând rezultatul acestui efort de armonizare metodologică. Ca alternativă a fost avută în vedere procedura X-13ARIMA-SEATS, dezvoltată de Biroul de Recensământ al Statelor Unite și larg utilizată în statistica oficială (Drăgușin, 2013).

Modelarea propriu-zisă a seriei consumului de energie electrică s-a realizat prin modele SARIMA, extensia sezonieră a modelelor autoregresive integrate de medie mobilă. Un model SARIMA combină o componentă nesezonieră și una sezonieră, fiecare cu termeni autoregresivi, de diferențiere și de medie mobilă, și se notează SARIMA(p,d,q)(P,D,Q)s. Forma generală a modelului este redată în relația [4] (Hyndman și Athanasopoulos, 2021).

$$\varphi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D y_t = \theta_q(B)\Theta_Q(B^s)\varepsilon_t \quad [4]$$

În această relație, B este operatorul de întârziere, care aplicat unei observații o transformă în observația din perioada anterioară, iar s este perioada sezonieră, egală cu douăsprezece în cazul datelor lunare. Polinoamele notate cu φ și θ descriu componentele autoregresivă și de medie mobilă nesezoniere, de ordin p, respectiv q, în timp ce polinoamele notate cu Φ și Θ descriu componentele sezoniere corespunzătoare, de ordin P, respectiv Q. Exponenții d și D indică numărul de diferențieri regulate, respectiv sezoniere, iar termenul de eroare este de tip zgomot alb.

Pe lângă specificarea bazată pe analiza corelogramelor, a fost utilizată și o procedură automată de identificare a ordinelor unui model ARIMA, care selectează specificarea prin combinarea testelor de rădăcină unitară cu minimizarea unui criteriu informațional (Hyndman și Athanasopoulos, 2021).

O a doua clasă de modele de previziune folosită a fost cea a modelelor de netezire exponențială în formă de spațiu al stărilor, cunoscute sub denumirea ETS (*Error, Trend, Seasonal*). Aceste modele descriu seria prin componente neobservabile de nivel, de pantă și sezonieră, fiecare actualizată recursiv în funcție de eroarea de previziune. În varianta aditivă cu

tendință și sezonalitate, modelul se poate scrie sub forma ecuațiilor din relația [5] (Hyndman și Athanasopoulos, 2021).

$$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t$$

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t$$

$$b_t = b_{t-1} + \beta\varepsilon_t$$

$$s_t = s_{t-m} + \gamma\varepsilon_t \quad [5]$$

În aceste ecuații, ℓ reprezintă nivelul seriei, b panta, s componenta sezonieră, iar m perioada sezonieră. Parametrii notați cu α, β și γ sunt parametri de netezire cuprinși între zero și unu, care controlează viteza de actualizare a fiecărei componente. Prima ecuație exprimă observația ca sumă a componentelor, iar celelalte trei descriu modul în care nivelul, panta și componenta sezonieră se actualizează de la o perioadă la alta.

Calitatea modelelor estimate a fost evaluată prin analiza reziduurilor. Un model adecvat trebuie să conducă la reziduuri de tip zgomot alb, adică lipsite de autocorelație. Pentru verificarea absenței autocorelației reziduale a fost utilizat testul Ljung-Box, a cărui statistică este prezentată în relația [6].

$$Q = T(T+2)\Sigma_{k=1}^{h}\left(\hat{\rho}^2_k/(T-k)\right) \quad [6]$$

Aici T este numărul de observații, h este numărul de întârzieri considerate, iar termenul ρ cu accent circumflex reprezintă autocorelația estimată a reziduurilor la întârzierea respectivă. Ipoteza nulă a testului este aceea că toate autocorelațiile până la întârzierea h sunt nule, deci reziduurile sunt zgomot alb, iar ipoteza alternativă presupune existența a cel puțin unei autocorelații nenule (Hyndman și Athanasopoulos, 2021).

Capacitatea de previziune a fost evaluată prin împărțirea seriei într-un eșantion de estimare și un eșantion de testare, performanța fiind măsurată pe baza erorilor obținute în afara eșantionului de estimare (Hyndman și Athanasopoulos, 2021). Pentru cuantificarea acurateței au fost folosiți mai mulți indicatori complementari. Eroarea medie pătratică și eroarea medie absolută măsoară mărimea erorilor în unitatea de măsură a seriei, eroarea medie absolută procentuală exprimă eroarea în termeni relativi, sub formă de procent, iar eroarea medie absolută scalată raportează eroarea modelului la cea a unei previziuni naive de referință, fiind utilă pentru comparații independente de scară. La aceștia s-au adăugat criteriul informațional Akaike în formă corectată, folosit pentru compararea modelelor estimate pe același eșantion, și intervalele de predicție, care exprimă incertitudinea asociată valorilor prognozate.

2.3. Analiza multivariată

Cea de-a doua direcție a analizei a extins cadrul univariat prin includerea simultană a mai multor serii și prin studierea relațiilor dintre acestea. Sistemul analizat a reunit consumul de energie electrică, indicele producției industriale și gradele-zile termice. Clasa de model adecvată unui astfel de sistem depinde de proprietățile de staționaritate ale seriilor componente (Shrestha și Bhatta, 2018). Atunci când toate seriile sunt staționare în nivel, sistemul poate fi modelat printr-un model vectorial autoregresiv în nivel. Atunci când seriile sunt nestaționare de același ordin și există între ele o relație de echilibru pe termen lung, este adecvat un model vectorial cu corecție a erorii. Atunci când seriile sunt nestaționare, dar fără o astfel de relație, sistemul se modelează în diferențe. Atunci când seriile au ordine de integrare diferite, se recurge la un model autoregresiv cu întârzieri distribuite.

Indiferent de clasa de model, un pas comun a fost stabilirea numărului de întârzieri incluse în sistem. Acesta a fost ales pe baza criteriilor informaționale, care echilibrează calitatea ajustării cu simplitatea modelului, penalizând includerea unui număr excesiv de parametri. Au fost avute în vedere criteriul Akaike, criteriul bayesian al lui Schwarz, criteriul Hannan-Quinn și eroarea finală de predicție (Colonescu, 2016).

Modelul vectorial autoregresiv tratează fiecare variabilă a sistemului ca funcție liniară de propriile valori întârziate și de valorile întârziate ale celorlalte variabile, fără a impune dinainte o ierarhie între ele. Pentru un sistem cu mai multe variabile, modelul de ordin p se scrie sub forma matriceală din relația [7] (Shrestha și Bhatta, 2018).

$$y_t = c + A_1 y_{t-1} + A_2 y_{t-2} + \ldots + A_p y_{t-p} + \varepsilon_t \qquad [7]$$

În această relație, y este vectorul variabilelor sistemului la un moment dat, c este vectorul termenilor constanți, matricile de coeficienți corespund fiecărei întârzieri incluse în model, iar termenul de eroare este un vector. Modelul permite analiza interdependențelor dintre variabile și constituie baza pentru instrumentele de interpretare descrise în continuare.

În cazul seriilor nestaționare integrate de ordin unu, prezintă interes posibilitatea existenței unei relații de echilibru pe termen lung între ele. Două sau mai multe serii nestaționare sunt cointegrate atunci când o combinație liniară a lor este staționară, ceea ce arată că, deși seriile evoluează relativ liber pe termen scurt, ele nu se îndepărtează permanent una de cealaltă (Shrestha și Bhatta, 2018). Existența și numărul relațiilor de cointegrare au fost stabilite cu testul Johansen, bazat pe statisticile din relația [8].

$$\lambda_{trace}(r) = -T\Sigma_{i=r+1}^{n} ln(1-\hat{\lambda}_i) \lambda_{max}(r, r+1) = -Tln(1-\hat{\lambda}_{r+1}) \qquad [8]$$

Prima statistică este statistica trace, iar a doua este statistica valorii proprii maxime, ambele construite pe baza valorilor proprii estimate, notate cu λ. În cazul statisticii trace, ipoteza nulă presupune existența a cel mult r relații de cointegrare, deci un rang cel mult egal cu r, față de ipoteza alternativă a unui rang superior. În cazul statisticii valorii proprii maxime, ipoteza nulă presupune existența a exact r relații de cointegrare, față de alternativa unui rang de cointegrare r+1 (Shrestha și Bhatta, 2018).

Atunci când cointegrarea este confirmată, sistemul se modelează printr-un model vectorial cu corecție a erorii, prezentat în relația [9] (Shrestha și Bhatta, 2018).

$$\Delta y_t = \Pi y_{t-1} + \Sigma_{i=1}^{p-1} \Gamma_i \Delta y_{t-i} + \varepsilon_t \quad [9]$$

În această relație, Δy reprezintă vectorul variabilelor diferențiate, matricea notată cu Π conține informația privind relațiile pe termen lung și se descompune ca produs între o matrice a vitezelor de ajustare și o matrice a vectorilor de cointegrare, matricile notate cu Γ descriu dinamica pe termen scurt, iar termenul de eroare este un vector. Termenul de corecție a erorii inclus în acest model arată în ce măsură abaterile de la echilibrul pe termen lung sunt corectate de la o perioadă la alta, viteza de ajustare indicând cât de rapid revine sistemul la echilibru după un dezechilibru.

În situația în care seriile sistemului au ordine de integrare diferite, combinând serii staționare în nivel cu serii nestaționare, a fost utilizat modelul autoregresiv cu întârzieri distribuite. Acest model explică variabila dependentă prin propriile valori întârziate și prin valorile curente și întârziate ale variabilelor explicative, fiind aplicabil indiferent dacă regresorii sunt integrați de ordin zero sau de ordin unu. Forma generală a modelului este redată în relația (10) (Shrestha și Bhatta, 2018).

$$y_t = c + \Sigma_{i=1}^{p} \varphi_i y_{t-i} + \Sigma_{j=1}^{k} \Sigma_{l=0}^{q_j} \beta_{j,l} x_{j,t-l} + \varepsilon_t \quad [10]$$

În această relație, y este variabila dependentă, în cazul de față consumul de energie electrică, variabilele explicative sunt notate cu x, coeficienții notați cu φ și β corespund întârzierilor proprii și, respectiv, regresorilor, iar ultimul termen este eroarea.

Existența unei relații de echilibru pe termen lung în cadrul acestei specificări a fost verificată prin testul Bounds, aplicat pe forma cu corecție a erorii din relația [11].

$$\Delta y_t = c + \Sigma_{i=1}^{p} \varphi_i \Delta y_{t-i} + \Sigma_{j=0}^{q} \theta_j \Delta x_{t-j} + \delta_1 y_{t-1} + \delta_2 x_{t-1} + \varepsilon_t \quad [11]$$

Testul Bounds este un test de tip F asupra coeficienților nivelurilor întârziate. Ipoteza nulă presupune absența unei relații de nivel, exprimată prin coeficienții δ1 și δ2 egali simultan cu zero, iar ipoteza alternativă presupune existența unei relații de echilibru pe termen lung. Statistica F calculată se compară cu două praguri critice, corespunzătoare situațiilor în care toți

regresorii sunt integrați de ordin zero, respectiv de ordin unu (Shrestha și Bhatta, 2018). Atunci când relația de termen lung este confirmată, un termen de corecție a erorii surprinde viteza de revenire la echilibru.

Pentru studierea relațiilor de tip cauză-efect în sens statistic a fost utilizat conceptul de cauzalitate Granger, evaluat pe baza regresiei din relația (12).

$$y_t = \alpha + \Sigma_{i=1}^{p} \beta_i y_{t-i} + \Sigma_{j=1}^{p} \gamma_j x_{t-j} + \varepsilon_t \quad [12]$$

O variabilă este considerată că o cauzează Granger pe o alta atunci când valorile sale trecute contribuie la îmbunătățirea previziunii celei de-a doua. Ipoteza nulă a testului este aceea că toți coeficienții valorilor întârziate ale variabilei explicative, notați cu γ, sunt simultan nuli, deci variabila respectivă nu o cauzează Granger pe cea dependentă, iar ipoteza alternativă presupune cel puțin un coeficient nenul. Testul a fost aplicat pe perechi de variabile, în ambele sensuri (Shrestha și Bhatta, 2018; Colonescu, 2016).

Dinamica sistemului ca răspuns la șocuri a fost analizată cu ajutorul funcției de răspuns la impuls și al descompunerii varianței erorii de previziune. Funcția de răspuns la impuls urmărește efectul în timp al unui șoc apărut într-una dintre variabile asupra celorlalte variabile ale sistemului, în timp ce descompunerea varianței erorii de previziune arată ce proporție din variația unei variabile este explicată de șocurile fiecărei variabile din sistem (Colonescu, 2016). Pentru identificarea șocurilor a fost folosită descompunerea Cholesky, care presupune o ordonare a variabilelor de la cea mai exogenă către cea mai endogenă. Validitatea acestor instrumente depinde de stabilitatea sistemului, condiție îndeplinită atunci când rădăcinile polinomului caracteristic au module subunitare, adică se află în interiorul cercului unitar.

Adecvarea modelelor multivariate a fost verificată printr-un set de teste asupra reziduurilor, prezentate în continuare. Absența autocorelației a fost testată cu un test de tip Portmanteau, varianta multivariată a testului Ljung-Box din relația (6), ipoteza nulă fiind absența autocorelației reziduale, iar cea alternativă, prezența ei (Colonescu, 2016).

Prezența heteroscedasticității de tip autoregresiv condiționat a fost testată cu testul ARCH, bazat pe regresia auxiliară din relația [13].

$$\hat{\varepsilon}^2_t = \alpha_0 + \Sigma_{i=1}^{q} \alpha_i \hat{\varepsilon}^2_{t-i} + v_t, LM = T \cdot R^2 \quad [13]$$

Statistica testului este produsul dintre numărul de observații și coeficientul de determinație al regresiei auxiliare a pătratelor reziduurilor. Ipoteza nulă presupune absența efectelor ARCH, adică toți coeficienții α sunt nuli, iar ipoteza alternativă presupune prezența heteroscedasticității condiționate (Colonescu, 2016).

Normalitatea reziduurilor a fost evaluată cu testul Jarque-Bera, prezentat în relația [14].

$$JB = (T/6)(S^2 + (1/4)(K-3)^2) \quad [14]$$

Statistica se construiește pe baza coeficientului de asimetrie, notat cu S, și a coeficientului de aplatizare, notat cu K. Ipoteza nulă este aceea că reziduurile provin dintr-o distribuție normală, caz în care asimetria este nulă, iar aplatizarea este egală cu trei, în timp ce ipoteza alternativă presupune abaterea de la normalitate (Colonescu, 2016).

În cazul modelului autoregresiv cu întârzieri distribuite, care reprezintă o ecuație unică, diagnoza autocorelației s-a realizat cu testul Breusch-Godfrey, bazat pe regresia auxiliară din relația [15].

$$\hat{\varepsilon}_t = x'_t\beta + \Sigma_{s=1}^{p}\rho_s\hat{\varepsilon}_{t-s} + v_t, \qquad LM = T \cdot R^2 \quad [15]$$

Reziduurile estimate sunt regresate pe variabilele explicative și pe propriile valori întârziate, iar statistica testului este produsul dintre numărul de observații și coeficientul de determinație. Ipoteza nulă presupune absența autocorelației până la ordinul p, adică toți coeficienții ρ sunt nuli, iar ipoteza alternativă presupune prezența autocorelației (Colonescu, 2016).

Heteroscedasticitatea a fost testată cu testul Breusch-Pagan, bazat pe regresia auxiliară din relația [16].

$$\hat{\varepsilon}^2_t = \alpha_0 + \Sigma_{j=1}^{k}\alpha_j x_{j,t} + v_t, \qquad LM = T \cdot R^2 \quad [16]$$

Pătratele reziduurilor sunt regresate pe variabilele explicative, iar statistica testului este, ca și anterior, produsul dintre numărul de observații și coeficientul de determinație. Ipoteza nulă presupune homoscedasticitate, adică toți coeficienții α sunt nuli, iar ipoteza alternativă presupune prezența heteroscedasticității (Colonescu, 2016).

Suplimentar testului Jarque-Bera, normalitatea reziduurilor a fost verificată și cu testul Shapiro-Wilk, a cărui statistică este prezentată în relația [17].

$$W = \left(\Sigma_{i=1}^{n} a_i x_{(i)}\right)^2 / \Sigma_{i=1}^{n}(x_i - \bar{x})^2 \quad [17]$$

În această relație, x cu indice între paranteze reprezintă valorile ordonate ale reziduurilor, a sunt coeficienți tabelați, iar x cu bară este media. Ipoteza nulă este aceea că reziduurile provin dintr-o distribuție normală, iar ipoteza alternativă presupune abaterea de la normalitate. Atunci când au fost identificate abateri privind autocorelația sau heteroscedasticitatea, au fost folosite erori standard robuste de tip HAC, care corectează inferența statistică (Colonescu, 2016).

Stabilitatea în timp a coeficienților a fost examinată cu testele CUSUM și OLS-CUSUM, construite pe baza statisticii din relația [18].

$$W_t = (1/\hat{\sigma})\Sigma_{j=k+1}^{t} w_t, \qquad t = k+1, \ldots, T \quad [18]$$

Statistica reprezintă suma cumulată a reziduurilor recursive, raportată la abaterea standard estimată. Ipoteza nulă este stabilitatea în timp a coeficienților modelului, iar ipoteza alternativă presupune o ruptură structurală a relației estimate. Depășirea de către traiectoria cumulată a unor benzi de încredere semnalează respingerea ipotezei de stabilitate (Colonescu, 2016).

CAPITOLUL 3. STUDIUL DE CAZ

Capitolul de față aplică instrumentarul metodologic descris anterior asupra datelor reale, prezentând rezultatele celor două direcții de analiză pentru cele 26 de state europene. Sunt expuse, pe rând, rezultatele analizei univariate, dedicate modelării și previziunii fiecărei serii de consum, și cele ale analizei multivariate, dedicate relației dintre consum, producția industrială și stresul termic.

3.1. Datele și variabilele analizate

Analiza empirică se bazează pe trei serii de date cu frecvență lunară, extrase din baza de date Eurostat pentru cele 26 de state europene incluse în studiu, acoperind perioada cuprinsă între ianuarie 2008 și 2025. Cele trei variabile, descrise în continuare, surprind consumul de energie electrică, nivelul activității industriale și stresul termic.

Consumul de energie electrică reprezintă variabila de interes central a lucrării și este o mărime observată direct, nu calculată. Aceasta exprimă cantitatea totală de energie electrică consumată lunar la nivel național și este măsurată în gigawați-oră (GWh). Seria a fost preluată ca atare din baza de date Eurostat și a fost utilizată în forma sa brută în analiza univariată, respectiv în formă ajustată sezonier, prin procedura TRAMO-SEATS, în analiza multivariată.

Evoluția consumului de energie electrică pe întreaga perioadă analizată este redată, pentru toate cele 26 de state suprapuse, în Figura 3.1. Reprezentarea evidențiază diferențele substanțiale de nivel dintre marile economii și statele mici, tiparul sezonier comun și efectul vizibil al perturbărilor din 2020 și din perioada crizei energetice.

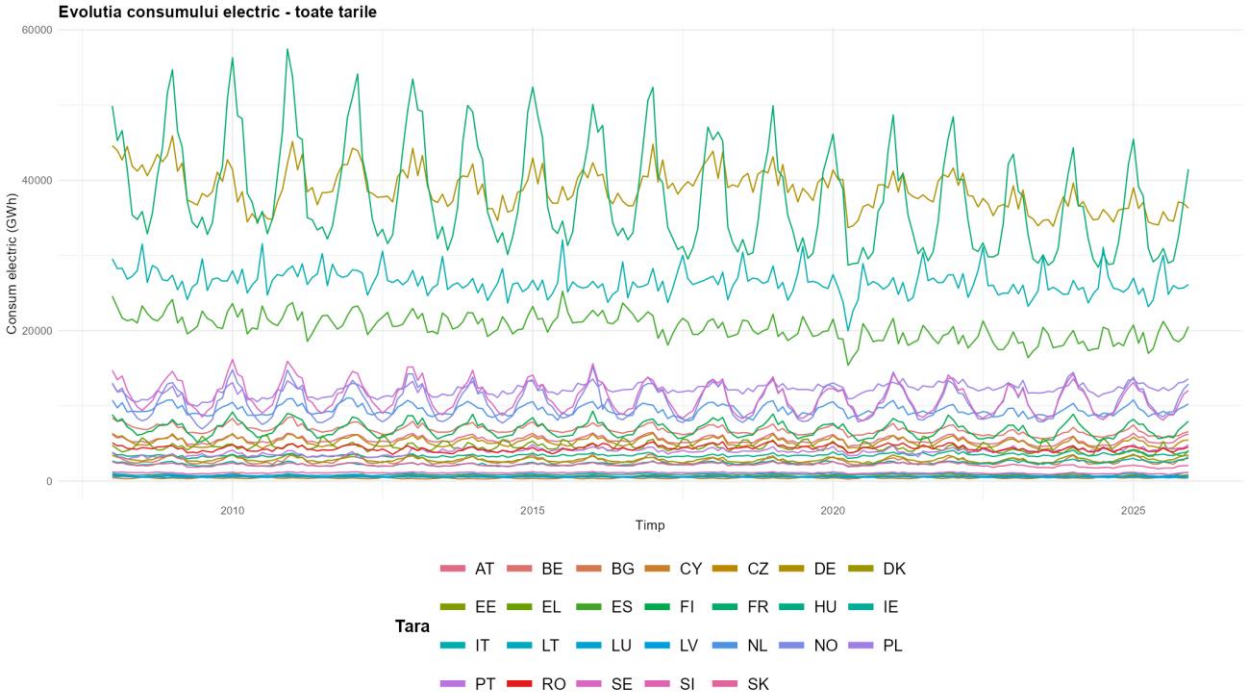


Figura 3.1. Evoluția consumului de energie electrică pentru țările europene
Sursa: Prelucrare proprie în R

Indicele producției industriale este utilizat ca aproximare a nivelului activității economice. Spre deosebire de consum, acesta nu este o mărime fizică, ci un indice fără unitate de măsură proprie, raportat la un an de bază pentru care valoarea sa este egală cu 100. Indicele este preluat din baza de date Eurostat în formă deja ajustată sezonier și de calendar, astfel încât valorile sale reflectă evoluția producției industriale eliberată de tiparele sezoniere și de efectul numărului diferit de zile lucrătoare de la o lună la alta.

Figura 3.2 prezintă evoluția indicelui producției industriale pentru cele 26 de state. Spre deosebire de consum, seriile sunt centrate în jurul valorii de referință 100 și pun în evidență contracția sincronizată din 2020, urmată de reveniri cu ritmuri diferite de la o țară la alta.

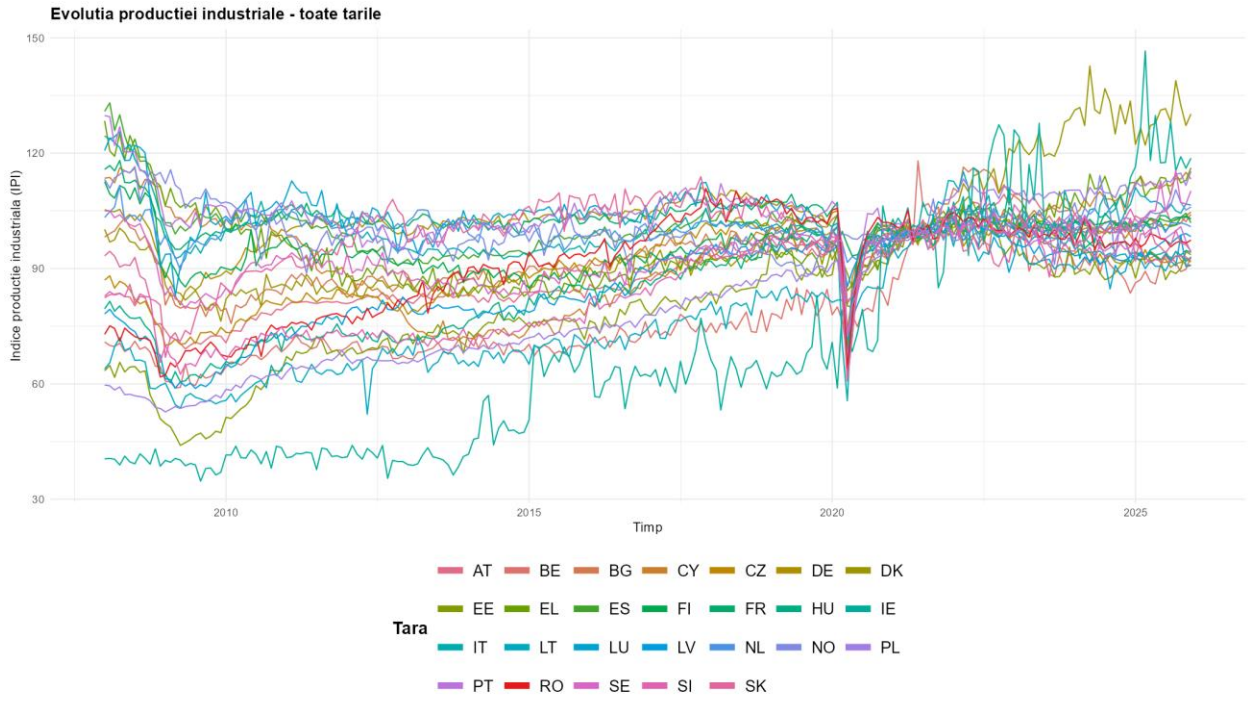


Figura 3.2. Evoluția indicelui de producție industrială pentru țările europene
Sursa: Prelucrare proprie în R

Gradele-zile termice constituie singura variabilă obținută prin calcul și sunt folosite ca aproximare a stresului termic care influențează cererea de energie. Această variabilă rezultă din însumarea gradelor-zile de încălzire și a gradelor-zile de răcire. Gradele-zile de încălzire cuantifică, pentru fiecare zi în care temperatura medie coboară sub un prag de referință, cât de mult se abate aceasta față de o temperatură de confort, iar gradele-zile de răcire cuantifică, în mod simetric, abaterea din zilele călduroase, în care temperatura medie depășește un al doilea

prag. Valorile zilnice sunt apoi însumate la nivel de lună. Conform metodologiei Eurostat, gradele-zile de încălzire se calculează ca diferența dintre 18°C și temperatura medie zilnică, în zilele în care aceasta este mai mică sau egală cu 15°C, iar gradele-zile de răcire ca diferența dintre temperatura medie zilnică și 21°C, în zilele în care aceasta este mai mare sau egală cu 24°C. Indicatorul total, exprimat în grade-zile, a fost obținut prin adunarea celor două componente și a fost, la rândul său, ajustat sezonier în analiza multivariată.

Evoluția gradelor-zile termice este ilustrată în Figura 3.3. Caracterul sezonier este aici cel mai pronunțat, cu vârfuri de iarnă dominate de componenta de încălzire și creșteri estivale mai modeste, asociate componentei de răcire și mai vizibile în statele sudice.

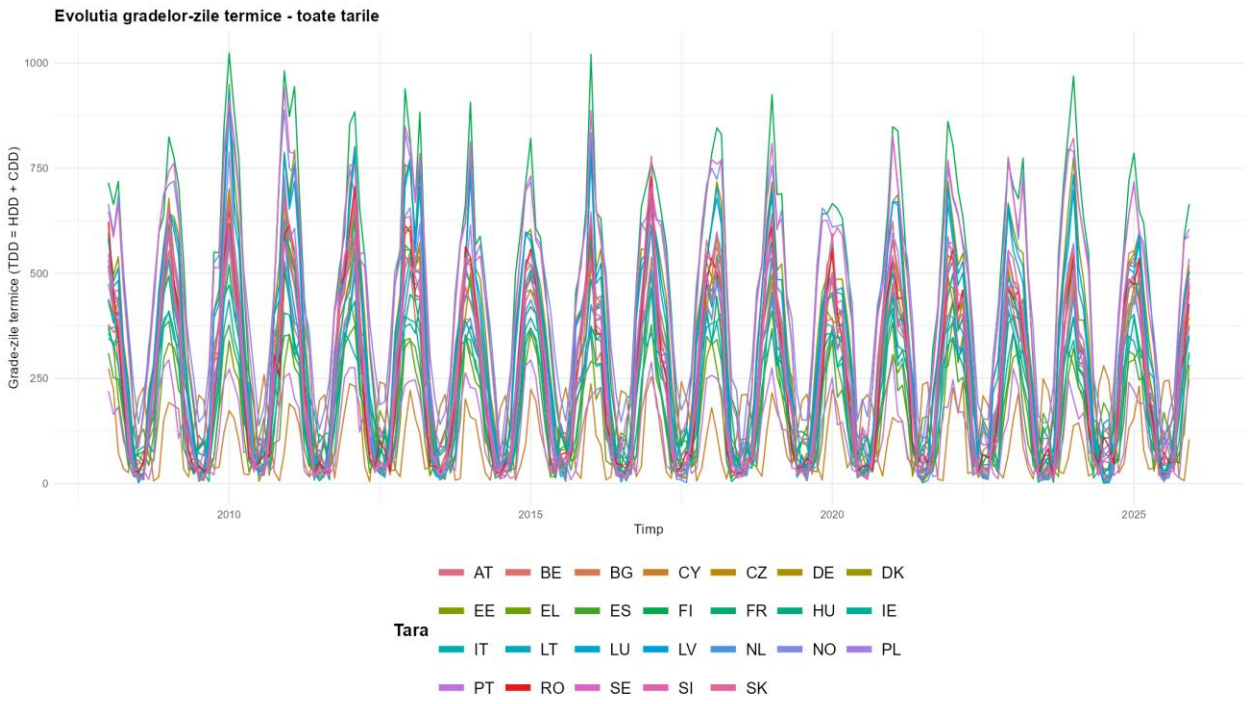


Figura 3.3. Evoluția gradelor-zile termice pentru țările europene
Sursa: Prelucrare proprie în R

3.2. Analiza univariată: prezentarea rezultatelor

3.2.1. Transformarea Box-Cox și staționarizarea

Decizia privind aplicarea transformării Box-Cox a fost luată individual pentru fiecare serie, pe baza valorii lambda estimate și a comparației vizuale dintre seria originală și cea transformată.

Tabelul nr. 3.1. Transformarea Box-Cox și specificarea modelelor SARIMA pe țări

Țara	Cod	Transformare Box-Cox (λ)	Model SARIMA specificat propriu (p,d,q)(P,D,Q)[12]	Justificarea specificării ordinelor
Austria	AT	Nu (λ = 2.000)	(2,1,2)(1,1,1)[12]	Testele de staționaritate au indicat că o singură diferențiere sezonieră nu este suficientă, fiind necesară și o diferențiere regulată pentru eliminarea tendinței reziduale. După dubla diferențiere, corelogramele au sugerat o structură non-sezonieră mixtă de tip ARMA(2,2), iar întârzierea de ordin 12, pronunțată în ambele funcții de autocorelație, a impus o componentă sezonieră formată din termenii SAR(1) și SMA(1).
Belgia	BE	Da (λ = -0.372)	(1,1,0)(1,1,1)[12]	Seria a necesitat atât o diferențiere sezonieră, cât și una regulată. Valoarea negativă a primei întârzieri în funcția de autocorelație parțială a indicat o componentă autoregresivă de ordinul întâi, al doilea termen, situat la limita pragului de semnificație, fiind eliminat pentru a preveni supraparametrizarea. Vârful de la întârzierea de ordin 12 a condus la termenii sezonieri SAR(1) și SMA(1).
Bulgaria	BG	Nu (λ = -1.000)	(1,0,1)(1,1,1)[12]	O singură diferențiere sezonieră a fost suficientă pentru staționarizare. Primele întârzieri semnificative din ambele corelograme au sugerat o structură non-sezonieră mixtă ARMA(1,1), completată de o componentă sezonieră SAR(1) și SMA(1). Specificația a fost menținută restrânsă pentru a evita supraajustarea, întrucât întârzierile suplimentare se aflau la limita pragului de semnificație.
Cipru	CY	Da (λ = -0.694)	(2,0,0)(1,1,1)[12]	După diferențierea sezonieră, funcția de autocorelație a prezentat o descreștere sinusoidală pe mai multe întârzieri, caracteristică unei componente autoregresive. Ordinul a fost fixat la AR(2), deși funcția de autocorelație parțială evidenția numai prima întârziere, în vederea unei mai bune echilibrări a reziduurilor. Componenta sezonieră a fost descrisă prin termenii SAR(1) și SMA(1).
Cehia	CZ	Nu (λ = 0.734)	(1,0,0)(1,1,1)[12]	Staționarizarea a necesitat o singură diferențiere sezonieră. Descreșterea treptată a funcției de autocorelație, însoțită de o întârziere dominantă în funcția parțială, a indicat o structură pur autoregresivă de ordinul întâi, completată de o componentă sezonieră SAR(1) și SMA(1).
Germania	DE	Da (λ = 0.351)	(1,1,1)(1,1,1)[12]	Descreșterea lentă a funcției de autocorelație după prima diferențiere a semnalat persistența unei tendințe reziduale, motiv

Țara	Cod	Transformare Box-Cox (λ)	Model SARIMA specificat propriu (p,d,q)(P,D,Q)[12]	Justificarea specificării ordinelor
				pentru care a fost introdusă o diferențiere regulată suplimentară. Corelogramele au indicat o structură mixtă ARMA(1,1) în dimensiunea non-sezonieră și o componentă sezonieră SAR(1) și SMA(1), rezultând specificația ARIMA(1,1,1)(1,1,1).
Danemarca	DK	Da (λ = 0.206)	(1,1,1)(1,1,1)[12]	Ca și în cazul precedent, descreșterea lentă a funcției de autocorelație a evidențiat o tendință reziduală, care a impus o diferențiere regulată suplimentară. Structura identificată din corelograme a reunit componente mixte în ambele dimensiuni, conducând la specificația ARIMA(1,1,1)(1,1,1).
Grecia	EL	Nu (λ = 1.698)	(1,0,2)(1,1,1)[12]	O singură diferențiere sezonieră a fost suficientă. Analiza corelogramelor a evidențiat o componentă non-sezonieră alcătuită dintr-un termen autoregresiv și doi termeni de medie mobilă, completată de o structură sezonieră SAR(1) și SMA(1).
Spania	ES	Da (λ = 1.546)	(2,1,0)(1,1,2)[12]	Seria a necesitat atât o diferențiere sezonieră, cât și una regulată. Corelogramele au indicat o componentă autoregresivă de ordinul doi în dimensiunea non-sezonieră, iar structura sezonieră a fost descrisă printr-o specificație mixtă, cu un termen SAR(1) și doi termeni SMA(2).
Finlanda	FI	Nu (λ = 0.203)	(2,0,0)(1,1,1)[12]	După diferențierea sezonieră, descreșterea treptată a funcției de autocorelație și dominanța primei întârzieri în funcția parțială, însoțită de o a treia întârziere marginal semnificativă, au condus la o componentă autoregresivă de ordinul doi. Componenta sezonieră a fost specificată prin termenii SAR(1) și SMA(1).
Irlanda	IE	Nu (λ = 0.751)	(2,1,1)(1,1,1)[12]	Descreșterea lentă a funcției de autocorelație a semnalat o tendință reziduală, care a impus o diferențiere regulată suplimentară. Corelogramele au indicat o structură non-sezonieră alcătuită dintr-o componentă autoregresivă de ordinul doi și un termen de medie mobilă, alături de componenta sezonieră SAR(1) și SMA(1).
Italia	IT	Nu (λ = 2.000)	(2,1,1)(2,1,1)[12]	Seria a necesitat ambele tipuri de diferențiere. Structura non-sezonieră, identificată din corelograme, a reunit o componentă autoregresivă de ordinul doi și un termen de medie mobilă, în timp ce dimensiunea sezonieră a fost descrisă printr-o specificație mai bogată, cu doi termeni autoregresivi SAR(2) și un termen de medie

Țara	Cod	Transformare Box-Cox (λ)	Model SARIMA specificat propriu (p,d,q)(P,D,Q)[12]	Justificarea specificării ordinelor
				mobilă SMA(1).
Lituania	LT	Nu (λ = 2.000)	(3,0,1)(1,1,1)[12]	O singură diferențiere sezonieră a fost suficientă. Funcția de autocorelație a descrescut lent, cu întârzieri semnificative până la ordinul cinci sau șase, iar funcția parțială a evidențiat o întârziere dominantă și o a doua situată la limita pragului, ceea ce a condus la o componentă autoregresivă de ordinul trei, completată de un termen de medie mobilă. Componenta sezonieră a fost specificată prin SAR(1) și SMA(1).
Luxemburg	LU	Da (λ = -1.000)	(2,1,1)(0,1,1)[12]	Variabilitatea rămasă după diferențierea sezonieră a impus și o diferențiere regulată. Corelogramele au indicat o componentă non-sezonieră alcătuită dintr-un termen autoregresiv de ordinul doi și unul de medie mobilă, în timp ce structura sezonieră a fost descrisă exclusiv printr-un termen de medie mobilă SMA(1).
Letonia	LV	Nu (λ = 0.381)	(2,1,1)(1,1,1)[12]	Diferențierea regulată suplimentară a condus la un semnal mai curat al seriei. Structura identificată din corelograme a reunit o componentă autoregresivă de ordinul doi și un termen de medie mobilă în dimensiunea non-sezonieră, alături de o componentă sezonieră SAR(1) și SMA(1).
Olanda	NL	Da (λ = -0.978)	(2,0,0)(1,1,1)[12]	După diferențierea sezonieră, descreșterea treptată a funcției de autocorelație și dominanța primelor întârzieri în funcția parțială au indicat o componentă autoregresivă de ordinul doi. Valoarea negativă a întârzierii de ordin 12 din funcția parțială, însoțită de o întârziere de ordin 24 marginală, a condus la termenii sezonieri SAR(1) și SMA(1).
Norvegia	NO	Nu (λ = 0.339)	(1,0,1)(1,1,1)[12]	O singură diferențiere sezonieră a fost suficientă. Corelogramele au sugerat o structură non-sezonieră mixtă ARMA(1,1), completată de o componentă sezonieră SAR(1) și SMA(1).
Polonia	PL	Nu (λ = 2.000)	(2,1,1)(1,1,1)[12]	Seria a necesitat atât o diferențiere sezonieră, cât și una regulată. Structura identificată din corelograme a reunit o componentă mixtă ARMA(2,1) în dimensiunea non-sezonieră și o componentă sezonieră SAR(1) și SMA(1).
Portugalia	PT	Nu (λ = 0.891)	(1,1,0)(0,1,2)[12]	Valoarea statisticii KPSS, situată mult peste pragul critic, a semnalat prezența unei tendințe stocastice, ceea ce a impus o diferențiere regulată suplimentară. Corelogramele au indicat o componentă autoregresivă de ordinul întâi în dimensiunea

Țara	Cod	Transformare Box-Cox (λ)	Model SARIMA specificat propriu (p,d,q)(P,D,Q)[12]	Justificarea specificării ordinelor
				non-sezonieră și doi termeni de medie mobilă sezonieri SMA(2).
România	RO	Da (λ = -0.139)	(1,1,1)(1,1,1)[12]	Seria a necesitat ambele tipuri de diferențiere. Corelogramele au sugerat o structură non-sezonieră mixtă ARMA(1,1), completată de o componentă sezonieră completă SAR(1) și SMA(1).
Suedia	SE	Da (λ = -0.611)	(1,0,1)(2,1,0)[12]	O singură diferențiere sezonieră a fost suficientă. Structura non-sezonieră, identificată din corelograme, a fost de tip ARMA(1,1), în timp ce componenta sezonieră a fost descrisă printr-un termen autoregresiv de ordinul doi SAR(2), o specificație alternativă echivalentă fiind SAR(1) și SMA(1).
Slovenia	SI	Nu (λ = 2.000)	(2,1,1)(1,1,1)[12]	Seria a necesitat atât o diferențiere sezonieră, cât și una regulată. Corelogramele au indicat o structură non-sezonieră alcătuită dintr-o componentă autoregresivă de ordinul doi și un termen de medie mobilă, alături de o componentă sezonieră SAR(1) și SMA(1).
Slovacia	SK	Da (λ = 1.199)	(1,1,0)(0,1,2)[12]	Seria a necesitat ambele tipuri de diferențiere. Tăierea bruscă a funcției de autocorelație după a doua întârziere și semnificația primelor întârzieri din funcția parțială au condus la o componentă autoregresivă de ordinul întâi, în timp ce vârfurile de la întârzierile de ordin 12 și 24 din funcția parțială au impus doi termeni de medie mobilă sezonieri SMA(2).
Franța	FR	Nu (λ = -0.657)	(1,0,1)(2,1,1)[12]	O singură diferențiere sezonieră a fost suficientă, întrucât funcția de autocorelație nu a prezentat o descreștere lentă persistentă. Corelogramele au indicat o structură non-sezonieră mixtă ARMA(1,1), iar componenta sezonieră a fost descrisă prin doi termeni autoregresivi SAR(2) și un termen de medie mobilă SMA(1).
Estonia	EE	Nu (λ = 1.369)	(1,0,1)(1,1,1)[12]	O singură diferențiere sezonieră a fost suficientă, seria fiind deja staționară în medie. Corelogramele au sugerat o structură non-sezonieră mixtă ARMA(1,1). Corelogramele au sugerat o structură non-sezonieră mixtă ARMA(1,1), completată de o componentă sezonieră SAR(1) și SMA(1)., completată de o componentă sezonieră SAR(1) și SMA(1).
Ungaria	HU	Da (λ = -1.000)	(0,1,0)(2,1,1)[12]	Valoarea statisticii KPSS, mult peste pragul critic, a semnalat o tendință stocastică, ceea ce a impus o diferențiere regulată suplimentară. Întrucât primele întârzieri ale

Țara	Cod	Transformare Box-Cox (λ)	Model SARIMA specificat propriu (p,d,q)(P,D,Q)[12]	Justificarea specificării ordinelor
				funcției parțiale se situau sub prag, componenta non-sezonieră a fost specificată ca un mers aleator cu drift sezonier (0,1,0), structura sezonieră fiind descrisă prin doi termeni autoregresivi SAR(2) și un termen de medie mobilă SMA(1).

Sursa: Prelucrare proprie în Excel

Pentru aproape jumătate dintre țări transformarea a fost respinsă, în special în cazurile în care lambda estimat se situa la limitele algoritmului (valori apropiate de 1.9999 sau de -0.9999), situații în care transformarea fie nu identifică o formă funcțională adecvată, fie introduce instabilitate numerică. Această din urmă observație merită subliniată: în cazul seriilor pentru care transformarea a fost totuși aplicată (de exemplu Belgia, Spania, Germania, Danemarca), datele trebuie readuse la scara originală în momentul generării prognozelor, întrucât menținerea valorilor pe scara transformată ar produce rezultate neinterpretabile în termeni reali și ar putea distorsiona intervalele de încredere, mai ales pentru seriile cu varianță neuniformă.

În privința staționarizării, toate cele 26 de serii au necesitat diferențiere sezonieră (D=1), reflectând caracterul puternic sezonier al consumului de energie electrică, indiferent de profilul climatic al țării. Distincția relevantă apare la nivelul diferențierii regulate: aproximativ jumătate dintre serii au fost staționarizate exclusiv prin diferențiere sezonieră, în timp ce restul au necesitat și o diferențiere regulată (d=1). Criteriile applicate pentru confirmarea stationaritatii au fost: testele KPSS, Phillips-Perron, ADF, ADF cu constantă, ADF cu constantă și trend (pentru testarea rădcăinii unitate) și graficele funcțiilor de autocorelație (ACF) si autocorelație parțială (PACF). În ciuda prezenței testelor pentru rădăcina unitară, cel mai des alegerea diferențierii regulate a fost făcută cu ajutorul funcțiilor de autcorelație, deoarece ofereau rezultate mai credibile decât testele folosite. Prezența unei descreșteri lente și persistente a funcției de autocorelație după diferențierea sezonieră, reprezintă un trend rezidual stocastic, iar unde testul KPSS pe seria originală depășea net pragul critic (cazurile Portugaliei și Ungariei sunt ilustrative), diferențierea regulată a fost impusă pentru a elimina componenta de trend.

3.2.2. Identificarea modelelor SARIMA specificate propriu

Specificația fiecărui model propriu a fost stabilită prin examinarea funcțiilor de autocorelație (ACF) și autocorelație parțială (PACF) ale seriei staționarizate. În general, structura

nesezonieră a fost dedusă din primele laguri: un lag PACF dominant urmat de o descreștere rapidă a sugerat componente autoregresive, în timp ce o tăiere bruscă a ACF a indicat componente de medie mobilă. Componenta sezonieră a fost identificată aproape uniform prin comportamentul lagului 12 (și ocazional al lagului 24): un lag 12 puternic negativ, prezent simultan în ACF și PACF, a justificat includerea atât a unui termen autoregresiv sezonier, cât și a unuia de medie mobilă sezonieră, conducând la structura recurentă (1,1,1) pentru partea sezonieră.

Un principiu metodologic aplicat consecvent a fost preferința modelelor mai simple în cazurile ambigue. Atunci când un lag se situa la limita pragului de semnificație, ordinul corespunzător a fost menținut redus pentru a diminua riscul de supraparametrizare; cazul Belgiei, unde al doilea lag PACF, deși semnificativ, a fost ignorat în favoarea unei specificații AR(1), ilustrează această abordare. Diversitatea profilurilor sezoniere a condus însă la o gamă largă de specificații: de la modele de tip random walk cu drift sezonier dublu (Ungaria) până la structuri sezoniere bogate cu doi termeni autoregresivi sezonieri (Franța, Italia, Spania).

3.2.3. Compararea modelelor și selecția modelului final

Pentru fiecare țară, modelul SARIMA propriu a fost pus în competiție cu un model SARIMA selectat automat și cu un model ETS, evaluarea finală fiind realizată pe baza acurateței atât in-sample cât și out-of-sample.

Tabelul nr. 3.2. Compararea acurateței modelelor SARIMA proprii, automate și ETS, in-sample, pe țări

Tara	Cod	Man RMSE	Man MAPE%	Man MASE	Man AICc	Auto RMSE	Auto MAPE%	Auto MASE	Auto AICc	ETS RMSE	ETS MAPE%	ETS MASE	ETS AICc
Austria	AT	117.93	1.50	0.48	2261.3	117.78	1.48	0.47	2268.8	115.94	1.54	0.49	2865.7
Belgia	BE	246.03	2.00	0.52	*-1964.3*	206.14	2.13	0.56	*-1981.2*	163.67	1.74	0.45	*2997.8*
Bulgaria	BG	120.40	3.18	0.67	2266.9	116.89	3.12	0.66	2260.0	116.44	3.23	0.68	2851.7
Cipru	CY	24.66	4.57	0.64	*-1970.4*	24.20	4.36	0.61	*-1978.2*	23.09	4.11	0.57	*2228.8*
Cehia	CZ	158.79	2.16	0.59	2371.5	151.91	2.10	0.57	2363.2	149.51	2.16	0.59	2960.5
Germania	DE	1091.40	2.03	0.45	*592.8*	1062.24	1.99	0.44	*586.3*	1056.37	2.01	0.45	*3710.2*
Danemarca	DK	79.94	2.07	0.57	*-142.8*	78.36	2.02	0.56	*-157.9*	79.36	2.10	0.58	*2708.2*
Grecia	EL	194.24	3.23	0.68	2441.2	191.93	3.20	0.67	2438.1	190.76	3.24	0.68	3050.6
Spania	ES	636.73	2.34	0.60	*4806.6*	611.13	2.20	0.56	*4814.5*	618.51	2.34	0.60	*3506.7*
Finlanda	FI	263.30	2.55	0.56	*-13.4*	248.83	2.40	0.53	*-21.9*	261.51	2.51	0.56	*3138.8*
Irlanda	IE	53.97	1.66	0.53	1986.1	61.79	1.88	0.60	2012.7	54.63	1.71	0.55	2567.0
Italia	IT	697.09	1.87	0.52	2897.4	692.56	1.87	0.52	2906.4	713.38	2.00	0.56	3564.2
Lituania	LT	32.72	2.72	0.51	*4256.4*	32.65	2.71	0.51	*4250.7*	31.79	2.66	0.50	*2362.6*
Luxemburg	LU	18.28	2.54	0.55	1595.2	17.96	2.52	0.54	1597.3	18.80	2.57	0.55	2165.6
Letonia	LV	18.22	2.12	0.54	*159.3*	18.18	2.15	0.54	*151.3*	19.14	2.30	0.58	*2163.5*
Olanda	NL	251.34	1.98	0.54	2538.4	250.00	1.98	0.54	2536.5	262.99	2.08	0.56	3181.9
Norvegia	NO	471.71	2.95	0.56	*562.3*	512.17	3.39	0.63	*577.9*	506.67	3.21	0.61	*3385.4*
Polonia	PL	286.74	1.71	0.58	*5943.5*	280.02	1.67	0.57	*5965.2*	287.06	1.84	0.62	*3211.1*
Portugalia	PT	158.11	2.94	0.53	2359.3	152.56	2.78	0.50	2365.0	150.82	2.92	0.52	2973.1
Romania	RO	143.12	2.43	0.44	2341.9	162.84	2.84	0.52	2373.9	147.70	2.57	0.47	2956.3
Suedia	SE	489.55	2.91	0.62	2772.7	445.69	2.69	0.57	2750.2	457.09	2.68	0.58	3345.8
Slovenia	SI	28.86	1.91	0.44	*4270.7*	29.11	1.97	0.46	*4289.3*	29.01	2.03	0.47	*2332.8*
Slovacia	SK	64.50	2.20	0.47	2055.5	70.07	2.36	0.50	2071.8	64.53	2.26	0.48	2638.7
Franta	FR	1864.80	3.23	0.60	3258.9	1782.19	3.11	0.58	3243.3	1789.04	3.24	0.61	3879.4
Estonia	EE	35.53	3.55	0.65	1836.0	35.75	3.59	0.66	1832.5	36.59	3.62	0.66	2397.1
Ungaria	HU	90.66	1.96	0.56	2161.4	85.14	1.86	0.53	2146.6	84.91	1.95	0.55	2745.0

Sursa: Prelucrare proprie în Excel

Tabelul anterior prezintă acuratețea celor trei abordări în interiorul eșantionului de estimare, măsurată prin indicatorii de eroare și prin criteriul informațional AICc. Performanța în interiorul eșantionului nu garantează însă o capacitate de generalizare similară, motiv pentru care selecția modelului final se întemeiază pe evaluarea în afara eșantionului. În acest sens, tabelul următor reunește specificațiile efective ale fiecărui model, performanța acestora în afara eșantionului de estimare și modelul final reținut pentru fiecare țară.

Tabelul nr. 3.3. Specificațiile modelelor, acuratețea și modelul final selectat, pe țări

Tara	Cod	SARIMA manual	Man RMSE	Man MAPE%	Man MASE	auto.arima	Auto RMSE	Auto MAPE%	Auto MASE	ETS (tip)	ETS RMSE	ETS MAPE%	ETS MASE	Model final
Austria	AT	(2,1,2)(1,1,1)[12]	437.54	6.39	2.07	(1,0,2)(0,1,2)[12]	289.85	4.23	1.37	ETS(M,N,A)	347.78	4.96	1.62	auto.arima
Belgia	BE	(1,1,0)(1,1,1)[12]	392.21	5.69	1.36	(1,0,2)(1,1,1)[12]	291.90	3.97	0.95	ETS(M,Ad,M)	279.84	3.84	0.92	ETS
Bulgaria	BG	(1,0,1)(1,1,1)[12]	186.58	4.88	1.09	(1,0,0)(0,1,1)[12]	213.20	6.26	1.36	ETS(M,N,M)	182.68	5.07	1.11	manual
Cipru	CY	(2,0,0)(1,1,1)[12]	76.79	13.55	2.33	(2,0,1)(1,1,1)[12]	61.23	10.33	1.79	ETS(M,Ad,M)	61.84	9.94	1.76	auto.arima
Cehia	CZ	(1,0,0)(1,1,1)[12]	248.78	4.73	1.19	(1,0,1)(2,1,1)[12]	156.63	2.78	0.71	ETS(M,N,A)	200.85	3.71	0.96	auto.arima
Germania	DE	(1,1,1)(1,1,1)[12]	956.69	2.31	0.47	(2,0,0)(0,1,1)[12]	953.42	2.17	0.45	ETS(M,N,A)	936.99	2.23	0.45	auto.arima
Danemarca	DK	(1,1,1)(1,1,1)[12]	266.92	7.43	2.19	(2,0,0)(1,1,1)[12]	274.19	7.53	2.22	ETS(M,N,A)	129.25	3.79	1.07	ETS
Grecia	EL	(1,0,2)(1,1,1)[12]	372.92	7.57	1.33	(2,0,1)(0,1,2)[12]	318.92	6.03	1.08	ETS(M,N,M)	324.71	6.50	1.19	auto.arima
Spania	ES	(2,1,0)(1,1,2)[12]	1143.21	4.92	1.18	(1,0,1)(0,1,1)[12]	834.06	3.46	0.83	ETS(M,N,A)	849.66	3.54	0.85	auto.arima
Finlanda	FI	(2,0,0)(1,1,1)[12]	256.92	3.12	0.64	(3,0,0)(1,1,1)[12]	265.96	3.33	0.69	ETS(M,N,A)	286.35	3.33	0.67	manual
Irlanda	IE	(2,1,1)(1,1,1)[12]	130.10	4.33	1.62	(1,1,1)(2,1,0)[12]	73.79	2.06	0.78	ETS(M,N,M)	156.28	5.40	2.00	auto.arima
Italia	IT	(2,1,1)(2,1,1)[12]	692.88	1.99	0.55	(1,0,1)(2,1,1)[12]	716.22	2.02	0.56	ETS(M,N,A)	1082.23	3.14	0.89	manual
Lituania	LT	(3,0,1)(1,1,1)[12]	96.34	10.28	1.73	(1,0,1)(0,1,1)[12]	98.39	10.59	1.77	ETS(M,N,A)	106.92	11.67	1.94	manual
Luxemburg	LU	(2,1,1)(0,1,1)[12]	22.29	3.54	0.75	(3,0,0)(0,1,2)[12]	20.58	3.49	0.71	ETS(M,N,A)	21.61	3.58	0.75	auto.arima
Letonia	LV	(2,1,1)(1,1,1)[12]	23.17	3.14	0.78	(1,0,1)(0,1,2)[12]	21.71	2.87	0.72	ETS(M,A,A)	21.82	2.99	0.74	auto.arima
Olanda	NL	(2,0,0)(1,1,1)[12]	215.53	1.82	0.50	(0,0,4)(0,1,1)[12]	313.13	2.79	0.78	ETS(A,N,A)	487.43	4.68	1.28	manual
Norvegia	NO	(1,0,1)(1,1,1)[12]	471.92	4.16	0.73	(0,0,0)(1,1,1)[12]	488.27	4.28	0.76	ETS(M,N,A)	318.67	2.54	0.47	ETS
Polonia	PL	(2,1,1)(1,1,1)[12]	573.49	3.82	1.36	(3,0,0)(0,1,1)[12]	308.63	2.12	0.74	ETS(M,N,A)	577.27	3.98	1.41	auto.arima
Portugalia	PT	(1,1,0)(0,1,2)[12]	106.82	2.07	0.42	(2,0,1)(0,1,2)[12]	103.24	1.98	0.40	ETS(A,A,A)	131.62	2.72	0.54	auto.arima
Romania	RO	(1,1,1)(1,1,1)[12]	202.01	3.84	0.68	(1,0,1)(2,1,0)[12]	138.26	2.71	0.49	ETS(M,N,A)	183.86	3.32	0.59	auto.arima
Suedia	SE	(1,0,1)(2,1,0)[12]	436.61	2.87	0.56	(1,0,0)(1,1,1)[12]	318.98	2.63	0.48	ETS(M,N,M)	445.04	3.55	0.68	auto.arima
Slovenia	SI	(2,1,1)(1,1,1)[12]	50.82	3.78	0.84	(1,0,1)(1,1,2)[12]	66.65	5.52	1.14	ETS(M,N,A)	50.08	3.90	0.84	manual
Slovacia	SK	(1,1,0)(0,1,2)[12]	98.29	4.36	0.79	(1,0,1)(2,1,0)[12]	172.22	8.17	1.47	ETS(M,N,A)	115.45	5.49	0.99	manual
Franta	FR	(1,0,1)(2,1,1)[12]	1015.82	2.25	0.37	(1,0,0)(0,1,2)[12]	1185.78	2.75	0.43	ETS(M,N,M)	1097.50	2.54	0.39	manual
Estonia	EE	(1,0,1)(1,1,1)[12]	36.20	4.11	0.71	(1,0,0)(0,1,1)[12]	37.25	4.30	0.74	ETS(M,N,A)	39.49	4.56	0.79	manual
Ungaria	HU	(0,1,0)(2,1,1)[12]	143.33	3.56	1.05	(1,0,0)(0,1,1)[12]	124.22	2.65	0.83	ETS(M,N,A)	102.89	2.51	0.76	auto.arima

Sursa: Prelucrare proprie în Excel

Repartiția modelelor finale între cele 26 de țări evidențiază că niciuna dintre cele trei abordări nu domină universal, alegerea depinzând de specificul fiecărei serii.

Cel mai instructiv tipar transversal este însă inversarea ierarhiei dintre evaluarea in-sample și cea out-of-sample, observată în aproximativ o treime dintre cazuri (Austria, România, Norvegia, Polonia, Irlanda și altele). În aceste situații, modelul SARIMA propriu obținea cel mai bun criteriu informațional AICc în interiorul eșantionului de estimare, însă era depășit net de modelul selectat automat în evaluarea out-of-sample. Acest fenomen constituie un semnal clasic de supraajustare: specificația proprie, mai bogată, se adapta excesiv la trăsăturile specifice ale datelor de antrenament, în detrimentul capacității de generalizare. România este un exemplu elocvent, modelul propriu conducea in-sample cu un AICc semnificativ mai bun, dar structura sezonieră cu doi termeni autoregresivi propusă de selecția automată (SAR(2)) a surprins mai eficient dinamica reală, conducând la o eroare procentuală out-of-sample de 2,71% față de 3,84% pentru modelul propriu. Această observație justifică retrospectiv decizia de a nu se baza exclusiv pe criteriile informaționale in-sample în selecția modelului final.

Un al doilea tipar valoros îl constituie cazurile de compromis între adecvarea reziduurilor și performanța predictivă, întâlnite în special pentru Slovenia, Slovacia și Ungaria. Pentru aceste țări, modelul cu cea mai bună acuratețe out-of-sample eșua testul Ljung-Box de absență a autocorelării reziduale, în timp ce un model alternativ, cu reziduuri adecvate, prezenta o performanță predictivă inferioară. Sursa autocorelării reziduale a fost, în mai multe cazuri, un outlier negativ pronunțat asociat perioadei de restricții din 2020. Decizia în aceste situații a fost diferențiată: pentru Slovenia și Slovacia, avantajul out-of-sample substanțial al modelului propriu (de aproape două, respectiv patru puncte procentuale, conform MAPE) a justificat alegerea sa, cu mențiunea explicită că autocorelarea reziduală rămasă introduce o incertitudine suplimentară în benzile de încredere ale prognozei; pentru Ungaria, unde atât modelul propriu cât și ETS prezentau probleme, modelul selectat automat a fost preferat ca cel mai bun compromis între acuratețe, validitatea reziduurilor și simplitate.

Modelul ETS s-a dovedit deosebit de competitiv pentru seriile cu amplitudine sezonieră foarte mare sau cu modificări ale amplitudinii în timp, situații în care structura sa multiplicativă captează mai fidel dinamica. Cazurile Danemarcei și Norvegiei sunt ilustrative: pentru Danemarca, modelele SARIMA nu s-au adaptat creșterii amplitudinii sezoniere către finalul perioadei, depășind o eroare de 7,4%, în timp ce ETS a redus-o la 3,79%; pentru Norvegia, structura multiplicativă ETS s-a dovedit superioară pentru o serie cu oscilații sezoniere de amplitudine ridicată, specifice climatului nordic. În schimb, ETS a eșuat sistematic testul de adecvare a reziduurilor pentru un număr important de serii, fiind eliminat din competiție în aceste cazuri în ciuda unei eventuale performanțe predictive bune.

Distribuția geografică a modelelor finale este ilustrată în Figura 3.4.

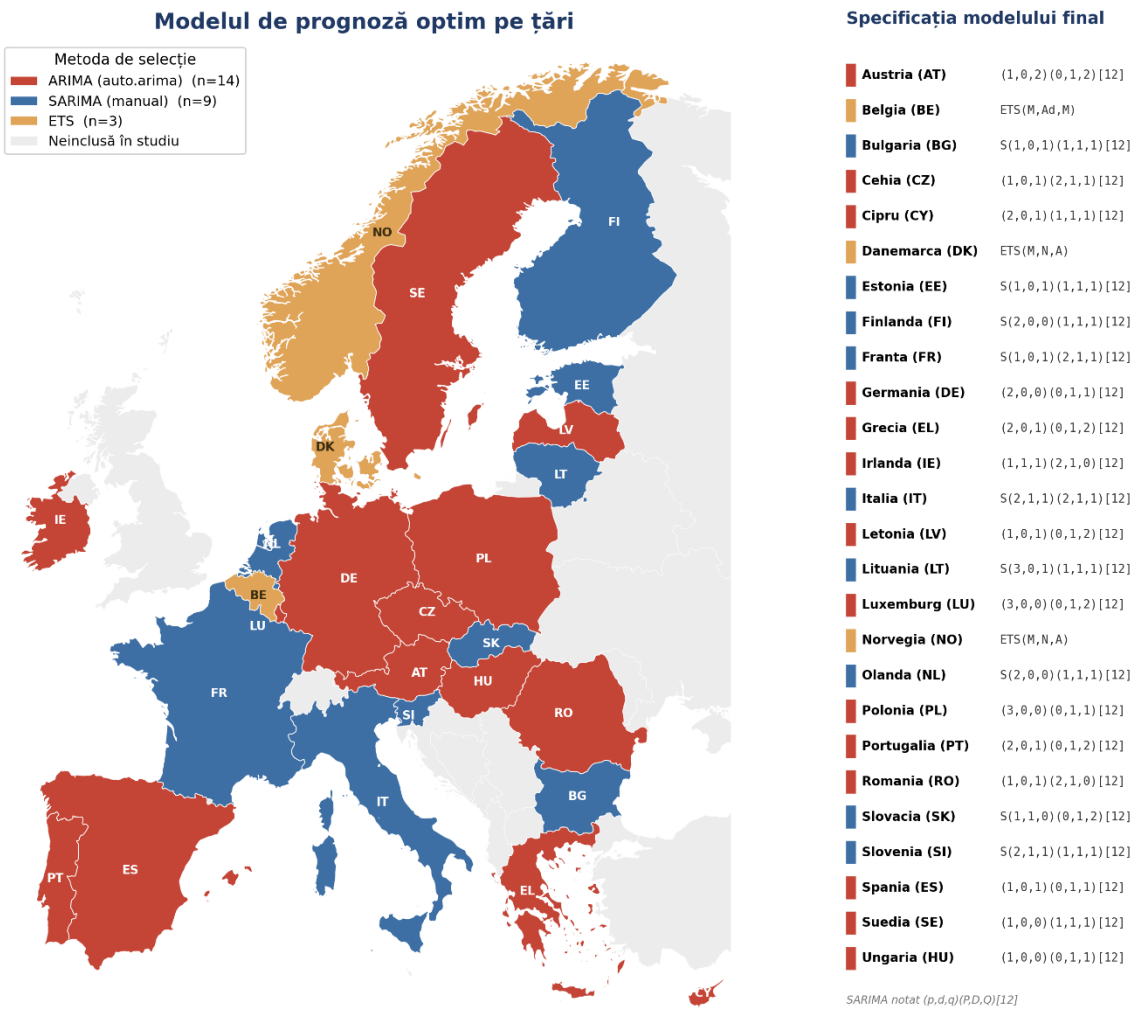


Figura 3.4. Modelul de prognoză optim pe țări
Sursa: Prelucrare proprie în R

Dincolo de selecția modelului optim pentru fiecare țară, prognozele generate de modelele univariate sunt redate, suprapus, în Figura 3.5. Reprezentarea permite compararea traiectoriilor previzionate ale consumului la nivelul întregului eșantion și evidențiază continuitatea tiparului sezonier în orizontul de prognoză.

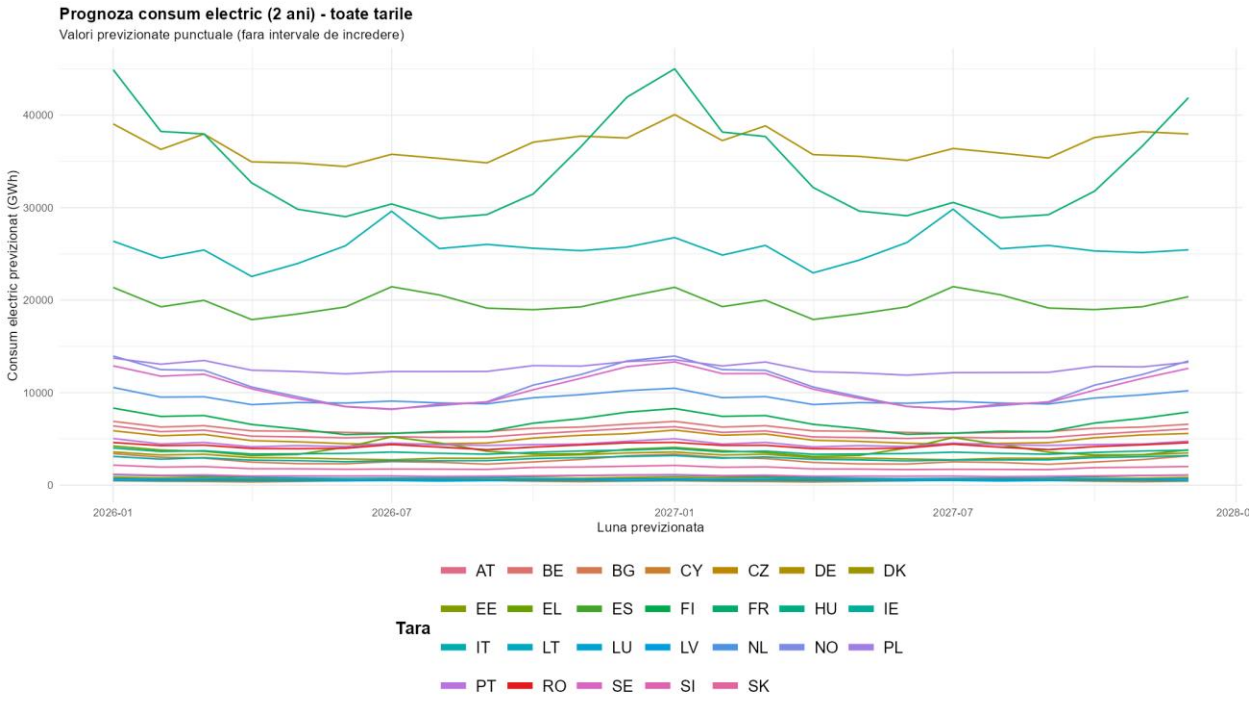


Figura 3.5. Evoluția previzionată a consumului electric în anii 2026-2027 pentru țările europene
Sursa: Prelucrare proprie în R

3.2.4. Context economic și interpretarea profilurilor de consum

Dincolo de specificațiile tehnice, profilurile de consum surprinse de modele reflectă particularități economice și climatice ale fiecărei țări.

Tabelul nr. 3.4. Contextul economic și interpretarea profilurilor de consum, pe țări

Tara	**Cod**	**Tipar sezonier**	**Trend & factor economic**	**Evenimente / anomalii**	**De ce modelul final**
Austria	AT	Climat racoros: maxime iarna, minim estival accentuat.	Medie aparent constantă, trend descrescator in jurul 2023.	Scădere bruscă a consumului în primăvara anului 2020 (restricții pandemice) și reduceri în intervalul 2022–2023 (criza energetică); valori atipic de ridicate în iarna anului 2012.	Modelul propriu este supra-ajustat. auto.arima este mai simplu și mai bun, conform metricilor out-of-sample.
Belgia	BE	Vest-european (Marea Nordului): consum ridicat iarna, scazut vara.	Media și varianța sunt inconstante (mai ales în prima parte); scădere medie in timp.	Contracții asociate restricțiilor pandemice (2020) și crizei energetice (finalul anului 2022), minimul fiind atins în iulie 2022; eveniment atipic identificat de descompunerea STL în jurul anului 2012.	Modelul auto.arima eșueaza testul Ljung-Box. ETS combina cea mai buna acuratete out-of-sample cu reziduuri valide.

Bulgaria	BG	Nordic/ continental: maxim iarna, minim vara.	Medie și variantă relativ constante.	Valoare atipică izolată înregistrată în aprilie 2018.	Modelul ETS este inadecvat (autocorelare reziduala). Modelul propriu are cele mai bune metrici de acuratețe.
Cipru	CY	Mediteranean: maxim vara, minim iarna.	Medie și variantă crescătoare spre final; nivel f. redus (~400-500 GWh).	Reducere pronunțată a consumului în aprilie 2020, corespunzătoare restricțiilor pandemice.	Modelul propriu subestimeaza varfurile; ETS marginal mai bun, dar am ales auto.arima pentru normalitatea reziduurilor.
Cehia	CZ	Central-european: maxim iarna, minim vara.	Ușoară scadere a mediei spre final.	Declin abrupt în anul 2020 și valori reduse în intervalul 2022–2023, atribuibile crizei energetice; minimul perioadei în 2023.	Modelul auto.arima are cel mai bun MAPE out-of-sample si cel mai mic AICc.
Germania	DE	Central-european.	Trend descrescător pronunțat (44.000 -> 36.000 GWh): eficiența/ dezindustri-alizare.	Scădere bruscă în anul 2020 și reduceri susținute în intervalul 2022–2023, pe fondul crizei energetice.	Modelul auto.arima are cel mai bun MAPE out-of-sample și AICc.
Danemarca	DK	Nord-european; amplitudine sezoniera crescatoare spre final.	Medie/ variantă constante.	Declin abrupt asociată restricțiilor din 2020; minimul absolut al seriei atins în 2023.	Modelul ETS (MAPE 3.79%) este mult mai performant decât ARIMA (>7.4%): ARIMA nu surprinde amplitudinea sezonieră crescătoare.
Grecia	EL	Mediteranean cu DOUA varfuri (iarna + vara, racire).	Medie relativ constantă, ușoara scădere spre final.	Vârf estival atipic în iulie 2012 și reduceri ale consumului în intervalul 2022–2023.	Modelul ETS inadecvat (autocorelare). auto.arima cele mai bune metrici out-of-sample si AICc.
Spania	ES	Mediteranean cu doua maxime (iarna + iulie, racire).	Trend descrescător moderat (22.000 -> 19.000 GWh).	Contracție extremă în aprilie 2020 (cea mai amplă reducere pandemică din eșantion) și valori reduse în intervalul 2022–2023.	Modelul auto.arima este singurul care trece testul + cele mai bune metrici out-of-sample.
Finlanda	FI	Nordic rece, amplitudine foarte mare, cu consum foarte ridicat iarna	Medie relativ constantă, cu o ușoara descreștere în timp.	Reducere a consumului estival în 2009 (criza financiară), urmată de minime în 2020 și 2022–2023.	Modelul ETS sever autocorelat. Modelul propriu este cele mai bune metrici out-of-sample si mai simplu.
Irlanda	IE	Vest-european.	Trend crescător pronunțat (2.300 -> >3.000 GWh):	Declin în anul 2020; valori reduse în intervalul 2013–2014.	Modelul auto.arima are metricile out-of-sample clar superioare (2.06% vs 4.33%), și

			creștere economică/ demografică, IT si centre de date.		se adapteaza mai bine la trendul crescător.
Italia	IT	Mediteranean, varf de vara (iul) mult mai pronuntat (>30.000 GWh).	Medie relativ constantă ~26.000 GWh.	Scădere drastică în aprilie 2020, printre cele mai ample reduceri pandemice din eșantion.	Modelul propriu cel mai bun MAPE si AICc desi mai complex.
Lituania	LT	Nordic: maxim iarna (>1.100 GWh), minim vara.	Constant ~900 GWh până în 2020, scadere după 2022.	Reduceri ale consumului în intervalul 2022–2024, în contextul crizei energetice și al conflictului regional, urmate de o revenire în 2025.	Diferențe out-of-sample mici; modelul propriu conduce, reziduuri aproape zgomot alb pur.
Luxemburg	LU	Vest-european mic: maxim ian/dec (>600 GWh), maxim secundar oct, minim aug.	Medie constantă ~530 GWh.	După 2020, consum redus și consistență sezonieră diminuată.	Modelul ETS eșueaza Ljung-Box, auto.arima are cele mai bune metrici de acuratețe.
Letonia	LV	Baltic: maxim iarna (>700 GWh), minim vara (<500 GWh).	Medie relativ constantă ~620 GWh.	Valoare ridicată în 2008; reduceri în intervalul 2024–2025 (criza energetică), cu o revenire moderată în 2025.	Modelul ETS eșuează complet. auto.arima are cele mai bune metrici out-of-sample si AICc (SMA(2) flexibil).
Olanda	NL	Vest-european, amplitudine constanta (structura aditiva).	Stabil ~9.500 GWh, ușoară scădere după 2015.	Valoare atipică identificată în 2015 și sezon estival cu consum redus în 2018.	Modelul ETS esueaza. Modelul propriu conduce clar metricile out-of-sample.
Norvegia	NO	Subarctic, amplitudine f. mare, cu consum tipic ridicat iarna.	Ușor descendent/stabil.	Vârf de consum excepțional în decembrie 2009; sezon estival anormal de redus în 2016, atribuibil variabilității hidrologice.	Modelul auto.arima esueaza (autocorelare). ETS net superior out-of-sample (2.54%), structura multiplicativa potrivita amplitudinii mari.
Polonia	PL	Central-european, amplitudine mai redusa decat în zona nordică.	Trend crescător clar (10.000 -> 13.800 GWh): creștere economică/ industriala.	Valoare atipic redusă în 2009 (criza financiară); efect vizibil, dar moderat, al restricțiilor din 2020.	ETS esueaza. Modelul auto.arima cu AR(3) fara d=1 prinde mai bine trendul crescator.
Portugalia	PT	Mediteranean, maxime vara și iarna.	Tranziție structurală ~2014 (2.900 -> 4.700 GWh): redresare după criza datoriilor; apoi rămâne constant.	Tranziție structurală a nivelului consumului în jurul anului 2014, urmată de stabilizare.	Modelul auto.arima conduce marginal (1.98% vs 2.07%).

Romania	RO	Continental-balcanic: varf iarna (ian) + varf estival (iul, climatizare).	Evoluție complexă: ridicat 2008-2009, minim 2013-2015, vârf 2017-2020, scădere 2021-2025.	Restructurare industrială ulterioară anului 2009; criza energetică din 2022 a determinat o comprimare vizibilă a consumului.	Modelul propriu supra-ajustat (AICc bun in-sample dar slab out-of-sample). auto.arima cu SAR(2) prinde dinamica sezoniera; net out-of-sample (2.71%).
Suedia	SE	Nordic, amplitudine f. mare.	Ușor descendent (15.000-16.000 -> 12.000-14.000 GWh iarna)	Vârf de consum în decembrie 2009, asociat unei ierni severe.	Modelul ETS esueaza. auto.arima superior și in-sample și out-of-sample (2.63%).
Slovenia	SI	Central-european.	Stabil ~1.050-1.150 GWh pana în 2019, scădere structurală după (<850 GWh in 2024-2025).	Reducere structurală a consumului ulterioară anului 2019, accentuată de criza energetică din 2022 și de măsurile de eficiență; valoare atipică în 2020.	COMPROMIS: Modelul propriu are cel mai bun out-of-sample (3.78%) dar eșueaza Ljung-Box (outlier 2020); am ales modelul specificat pentru avantaj out-of-sample de ~2 puncte procetuale, cu rezerva pe autocorelare reziduala.
Slovacia	SK	Central-european.	Trend descendent accentuat (2.550 -> 1.750-2.100 GWh): restructurare industrie grea energointensiva.	Declin susținut în intervalul 2022–2023, în contextul crizei energetice.	COMPROMIS: Modelul propriu are cele mai bune performanțe out-of-sample (4.36%), dar esueaza marginal Ljung-Box; ales pentru avantaj out-of-sample de ~4 pp.
Franta	FR	Oceanic temperat, amplitudine f. mare cu maxime sezoniere in perioadele reci.	Trend descendent clar (50.000-57.000 -> 40.000-47.000 GWh): eficienta, renovare.	Variabilitate accentuată a consumului ulterioară anului 2019, pe fondul crizei energetice din 2022 și al disponibilității reduse a parcului nuclear.	ETS esueaza. Modelul specificat conduce out-of-sample (desi auto.arima AICc mai bun in-sample); structura sezoniera bogata generalizeaza dinamica recenta.
Estonia	EE	Baltic cu maxime iarna.	Stabil ~700 GWh (economie mica); volatilitate anuală mare (temperatura).	Valori estivale anormal de ridicate în 2018, posibil afectate de erori de înregistrare.	ETS esueaza. Diferente out-of-sample mici; modelul specificat conduce marginal.
Ungaria	HU	Continental cu două vârfuri (ian + iul); ambele mai pronunțate recent	Trend crescător după ~2015 (3.200 -> 4.000 GWh): expansiune	Valoare atipic redusă în anul 2020, corespunzătoare restricțiilor pandemice.	COMPROMIS: ETS conduce out-of-sample (2.51%), dar eșuează testul Ljung-Box, la fel ca modelul

		(climatizare).	economica, investiții auto.		specificat .

Sursa: Prelucrare proprie în Excel

Din perspectivă comparativă, se pot distinge trei mari tipare sezoniere. Primul, dominant în nordul și centrul Europei (țările nordice, baltice, Germania, Cehia, Polonia), este unul pur de încălzire, cu un maxim de iarnă și un minim estival, amplitudinea fiind cu atât mai mare cu cât climatul este mai rece; Franța, Norvegia, Suedia și Finlanda prezintă cele mai accentuate oscilații sezoniere din setul analizat, în cazul Franței amplificate de dependența de încălzirea electrică alimentată de parcul nuclear. Al doilea tipar, specific sudului Europei (Grecia, Italia, Spania, Portugalia), este unul cu două vârfuri anuale; unul de iarnă și unul estival, acesta din urmă reflectând cererea de climatizare. Cazul Ciprului este singular, prezentând un profil complet inversat, cu maxim vara și minim iarna.

În privința tendințelor pe termen lung, analiza evidențiază o divergență economică semnificativă între state. O serie de țări manifestă un trend descrescător pronunțat al consumului: Germania (de la aproximativ 44.000 la 36.000 GWh), Franța, Suedia, Slovacia; atribuibil unei combinații de eficientizare energetică, restructurare industrială și, în cazuri precum Slovacia, contracției industriei grele energointensive. La polul opus, Irlanda, Polonia și Ungaria înregistrează trenduri ascendente clare, reflectând creșterea economică și demografică, expansiunea industrială (investițiile auto în Ungaria) sau dezvoltarea sectoarelor intensive în energie precum centrele de date (Irlanda). Această eterogenitate a dinamicilor naționale subliniază că, deși metodologia de modelare a fost uniformă, factorii structurali care guvernează consumul de energie electrică diferă substanțial între statele europene.

Două evenimente exogene majore sunt vizibile transversal în aproape toate seriile: contracția bruscă a consumului din primăvara anului 2020, asociată restricțiilor pandemice, și reducerea consumului din perioada 2022-2023, generată de criza energetică declanșată în contextul geopolitic regional. Amplitudinea primului șoc a variat considerabil între țări, de la scăderi dramatice în Spania și Italia (sub pragurile istorice) până la efecte mai atenuate în statele central-europene, în timp ce criza energetică a determinat o comprimare mai persistentă și mai generalizată a consumului, vizibilă ca o deplasare descendentă a profilurilor sezoniere recente față de cele anterioare.

3.3. Analiza multivariată: prezentarea rezultatelor

Alegerea clasei de modele a fost determinată de natura datelor. Testarea ordinului de integrare a condus, pentru toate cele 26 de țări, la aceeași configurație: un amestec de serii

integrate de ordine diferite, în care consumul și producția industrială sunt în general I(1), iar temperatura este I(0). Această combinație, cu verificarea prealabilă că nicio serie nu este I(2), exclude atât modelul VAR în niveluri (inaplicabil seriilor nestaționare), cât și modelul vectorial cu corecție a erorii (care presupune toate seriile I(1) și cointegrate), impunând modelul ARDL (Autoregressive Distributed Lag) cu testare prin procedura bounds. Faptul că aceeași clasă de model s-a aplicat uniform tuturor țărilor asigură consistența comparației transversal. Specificația individuală a ordinelor de întârziere a fost selectată prin criteriul informațional Akaike, pentru fiecare țară în parte.

3.3.1. Existența relației de termen lung

Elementul central al modelării ARDL îl constituie testul bounds, care stabilește dacă variabilele întrețin o relație de echilibru pe termen lung. Verdictul a fost considerat ferm doar atunci când ambele statistici ale testului, mai exact statistica F și statistica t, se situau de aceeași parte a pragurilor critice. Aplicând acest criteriu strict, cele 26 de țări se împart în trei grupuri distincte.

Tabelul nr. 3.5. Rezultatele estimării ARDL: testul bounds, verdictul relației de termen lung, termenul de corecție și multiplicatorii, pe țări

Tara	Cod	Ordin integrare (Elec/IPI/TDD)	Model ARDL	Bounds F	Bounds t	Relatie TL	ECT	ECT p	Multipl. LR IPI	Multipl. LR TDD
Austria	AT	I(1)/I(1)/I(0)	ARDL(7, 12, 3)	2.57	-2.77	**NU**	-0.1159	0.0058	*-11.27*	*-0.49*
Belgia	BE	I(1)/I(1)/I(0)	ARDL(3, 12, 3)	5.73	-3.94	**DA**	-0.1999	0.0000	-25.49	3.26
Bulgaria	BG	I(1)/I(1)/I(0)	ARDL(3, 12, 4)	7.58	-4.72	**DA**	-0.3906	0.0000	-7.13	1.44
Cipru	CY	I(1)/I(1)/I(0)	ARDL(1, 12, 1)	14.66	-6.60	**DA**	-0.3634	0.0000	2.68	0.49
Cehia	CZ	I(1)/I(1)/I(0)	ARDL(6, 12, 3)	2.27	-2.19	**NU**	-0.1046	0.0094	*-11.87*	*-1.51*
Germania	DE	I(1)/I(1)/I(0)	ARDL(2, 12, 0)	12.11	-4.49	**DA**	-0.1709	0.0000	275.83	35.15
Danemarca	DK	I(1)/I(1)/I(0)	ARDL(2, 12, 2)	4.41	-3.37	**Inconcludent**	-0.1677	0.0003	5.14	1.57
Grecia	EL	I(1)/I(1)/I(0)	ARDL(4, 12, 4)	0.81	-1.29	**NU**	-0.0604	0.1179	*-18.62*	*-3.07*
Spania	ES	I(1)/I(1)/I(0)	ARDL(9, 12, 10)	0.37	-0.04	**NU**	-0.0012	0.2940	*1401.42*	*-2112.16*
Finlanda	FI	I(1)/I(1)/I(0)	ARDL(6, 12, 5)	5.74	-3.95	**DA**	-0.2484	0.0000	-32.21	4.47
Irlanda	IE	I(1)/I(1)/I(0)	ARDL(5, 12, 5)	4.45	-3.28	**Inconcludent**	-0.1462	0.0003	7.11	0.95
Italia	IT	I(1)/I(0)/I(0)	ARDL(5, 12, 3)	4.88	-3.56	**DA**	-0.2901	0.0002	148.72	16.91
Lituania	LT	I(1)/I(1)/I(0)	ARDL(10, 12, 12)	2.25	-2.02	**NU**	-0.0779	0.0098	*-3.29*	*-1.71*
Luxemburg	LU	I(1)/I(1)/I(0)	ARDL(12, 12, 12)	4.56	-3.65	**Divergent (slab DA)**	-0.4195	0.0003	2.11	0.17
Letonia	LV	I(1)/I(1)/I(0)	ARDL(2, 12, 2)	7.57	-4.68	**DA**	-0.2386	0.0000	0.15	0.05
Olanda	NL	I(0)/I(1)/I(0)	ARDL(1, 12, 1)	11.43	-5.76	**DA**	-0.2861	0.0000	5.08	3.16
Norvegia	NO	I(0)/I(1)/I(0)	ARDL(3, 12, 2)	5.25	-3.66	**DA**	-0.2281	0.0001	-16.24	7.44
Polonia	PL	I(1)/I(1)/I(0)	ARDL(3, 12, 0)	4.06	-3.07	**Inconcludent**	-0.1663	0.0006	16.32	1.74
Portugalia	PT	I(1)/I(1)/I(0)	ARDL(10, 12, 8)	1.82	-2.13	**NU**	-0.0668	0.0198	*-49.85*	*0.74*
Romania	RO	I(1)/I(1)/I(0)	ARDL(5, 12, 5)	2.39	-2.34	**NU**	-0.0971	0.0078	*11.59*	*-2.18*
Suedia	SE	I(1)/I(1)/I(0)	ARDL(4, 12, 2)	4.11	-3.11	**Inconcludent**	-0.1373	0.0005	-56.41	10.83
Slovenia	SI	I(1)/I(1)/I(0)	ARDL(10, 12, 10)	8.56	-4.52	**DA**	-0.2031	0.0000	-3.44	-0.45
Slovacia	SK	I(1)/I(1)/I(0)	ARDL(5, 12, 1)	4.37	-1.92	**Inconcludent**	-0.0548	0.0004	15.98	7.40
Franta	FR	I(1)/I(0)/I(0)	ARDL(5, 12, 6)	0.74	-1.44	**NU**	-0.0561	0.1367	*-57.43*	*36.02*
Estonia	EE	I(0)/I(1)/I(0)	ARDL(2, 12, 2)	10.04	-5.48	**DA**	-0.3810	0.0000	1.28	0.34
Ungaria	HU	I(1)/I(1)/I(0)	ARDL(10, 12, 9)	3.95	-2.23	**Inconcludent**	-0.1347	0.0007	7.49	-3.30

Sursa: Prelucrare proprie în R

Pentru **unsprezece țări relația de termen lung este confirmată** de ambele statistici: Belgia, Bulgaria, Cipru, Germania, Estonia, Finlanda, Italia, Letonia, Olanda, Norvegia și Slovenia. În aceste cazuri, termenul de corecție a erorii poate fi interpretat legitim ca mecanism de ajustare către echilibru. Pentru **opt țări relația este respinsă** de ambele statistici (Austria,

Cehia, Spania, Franța, Grecia, Lituania, Portugalia și România) ceea ce înseamnă că variabilele nu întrețin un echilibru stabil, iar eventualii coeficienți de termen lung sunt lipsiți de conținut interpretabil. Restul de **șapte țări se află într-o zonă inconcludentă sau divergentă**, în care statistica F cade între pragurile critice ori cele două statistici oferă verdicte diferite (Danemarca, Irlanda, Luxemburg, Polonia, Slovacia, Suedia, Ungaria); pentru acestea, relația de termen lung este, în cel mai bun caz, slab susținută, iar termenul de corecție nu poate fi interpretat ca un mecanism de ajustare propriu-zis, ci exclusiv ca o reversiune slabă la medie.

Distribuția geografică a verdictului relației de termen lung, împreună cu specificația modelului ARDL estimat pentru fiecare țară, este prezentată în Figura 3.6. Se observă că țările cu relație confirmată se concentrează preponderent în nordul și centrul Europei, în timp ce zona mediteraneană și Europa de est prezintă mai frecvent absența echilibrului pe termen lung sau rezultate inconcludente.

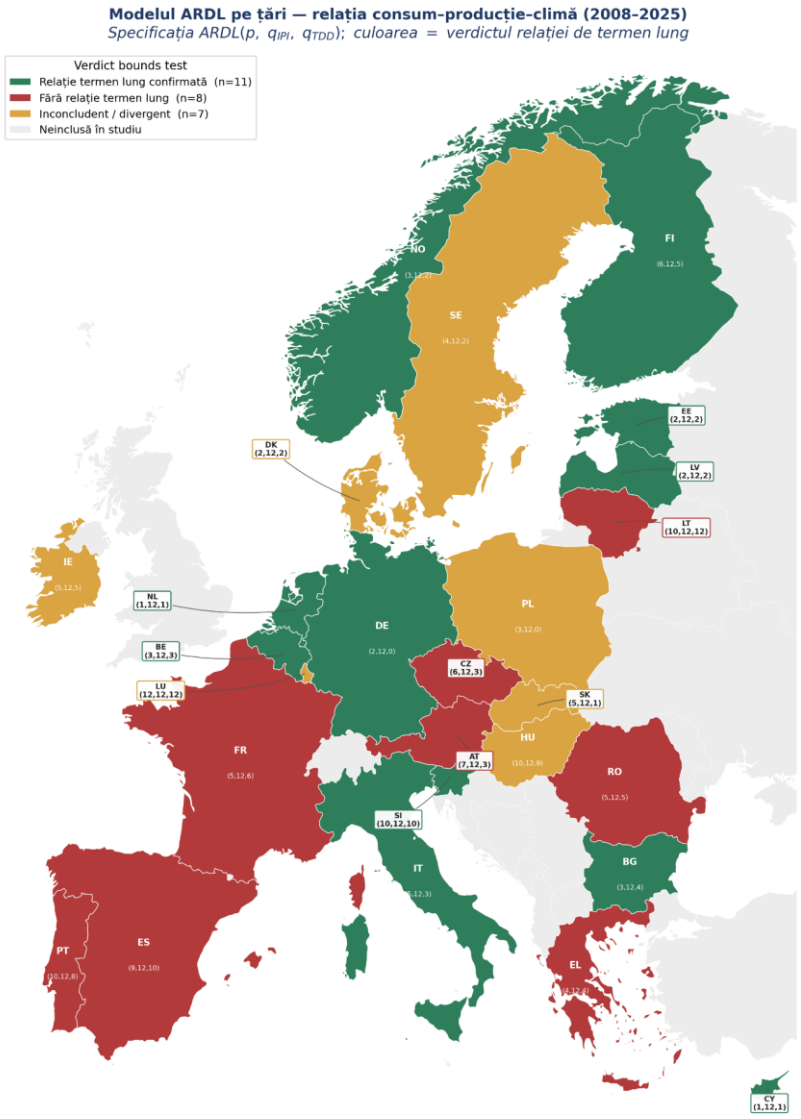


Figura 3.6. Modelul ARDL pe țări: relația consum-producție-climă, 2008-2025

Sursa: Prelucrare proprie în R

3.3.2. Termenul de corecție și tensiunea reversiune–cointegrare

Pentru țările cu echilibru confirmat, termenul de corecție a erorii (ECT) este negativ, semnificativ și subunitar în valoare absolută, indicând o ajustare stabilă. Viteza de ajustare variază considerabil între aceste state: de la valori moderate, în jurul a 17-20% din dezechilibru eliminat lunar (Germania, Belgia, Slovenia), până la ajustări rapide de aproape 40% pe lună (Bulgaria, Estonia, Cipru). Această eterogenitate reflectă diferențe structurale în rigiditatea pieței energetice naționale, cu cât viteza este mai mare, cu atât sistemul revine mai prompt la echilibru după un șoc.

Un aspect metodologic important privește **cazurile în care termenul de corecție este semnificativ deși testul bounds respinge relația de termen lung** (Austria, Cehia, Lituania, Portugalia, România). Această situație creează o ambiguitate interpretativă. Pe de o parte, un ECT semnificativ în absența cointegrării confirmate nu se citește ca o corecție de eroare propriu-zisă, ci ca o simplă reversiune slabă la medie a consumului. Pe de altă parte, atunci când coeficientul ECT este apropiat de zero, ca în cazul României, cu doar 9,7% pe lună, împărțirea la el în formula multiplicatorilor de termen lung produce valori artificial inflate. Cazul României este ilustrativ: multiplicatorii rezultați (un coeficient pozitiv mare pentru producția industrială și unul negativ pentru temperatură) sunt atât nesemnificativi statistic, cât și economic implauzibili, și trebuie tratați explicit ca rezultate numerice lipsite de justificare economică ale unei împărțiri la un coeficient neglijabil, nu ca o relație de echilibru reală. În tabele, multiplicatorii de termen lung pentru aceste țări sunt marcați distinct, tocmai pentru a semnala că nu sunt interpretabili.

3.3.3. Semnul producției industriale în relația de echilibru

Un tipar transversal neașteptat privește semnul cu care producția industrială intră în relația de termen lung. Din punct de vedere economic, ar fi de așteptat ca o producție industrială mai mare să fie asociată cu un consum de electricitate mai mare, adică un semn pozitiv. Totuși, chiar și printre țările cu echilibru confirmat, semnul este negativ în mai multe cazuri (Belgia, Bulgaria, Finlanda, Norvegia, Slovenia), uneori cu magnitudine substanțială și semnificație statistică ridicată. Această configurație atipică nu trebuie interpretată ca o relație inversă reală între industrie și consum, ci este atribuibilă restructurării industriale și rupturilor structurale prezente în seria producției industrial, în special declinul permanent al ramurilor energointensive surprins de profilul de drum aleator al seriei IPI. Acolo unde semnul este pozitiv și semnificativ (Germania, Italia, Olanda, Estonia, Letonia, Cipru), relația de echilibru are interpretarea economică așteptată, producția industrială susținând consumul pe termen lung. Temperatura, în

schimb, intră de regulă cu semnul corect și cu magnitudine substanțială în țările cu echilibru confirmat, confirmând rolul stresului termic ca determinant climatic robust al consumului.

3.3.4. Diagnosticarea modelelor

Adecvarea statistică a modelelor a fost evaluată prin testele uzuale pe reziduuri și prin analiza stabilității coeficienților.

Tabelul nr. 3.6. Diagnozele reziduurilor, stabilitatea CUSUM și performanța predictivă out-of-sample, pe țări.

Tara	Cod	Breusch-Godfrey (lag4/lag8)	Breusch-Pagan p	Jarque-Bera p	CUSUM stabil	ARDL MAPE%	RW MAPE%	MEAN MAPE%	SEAS MAPE%	Castigator OOS
Austria	AT	0.2527 / 0.3588	0.41	0.08	DA	4.25	2.81	3.03	7.53	**RW**
Belgia	BE	0.4772 / 0.5915	0.54	0.00	DA	3.88	2.68	10.91	4.62	**RW**
Bulgaria	BG	0.4506 / 0.7991	0.48	0.00	DA	4.05	4.75	3.38	5.16	**MEAN**
Cipru	CY	0.0271 / 0.0189	0.93	0.00	DA	1.68	2.70	15.17	2.38	**ARDL**
Cehia	CZ	0.8015 / 0.8483	0.66	0.00	DA	1.65	2.83	3.60	2.01	**ARDL**
Germania	DE	0.4155 / 0.6067	0.00	0.12	NU	1.48	1.21	7.46	1.31	**RW**
Danemarca	DK	0.6368 / 0.2079	0.06	0.00	DA	2.57	2.16	8.52	7.02	**RW**
Grecia	EL	0.0068 / 0.0212	0.12	0.00	NU	7.42	12.12	18.65	4.92	**SEAS**
Spania	ES	0.1689 / 0.4121	0.79	0.00	NU	0.72	1.74	4.66	4.03	**ARDL**
Finlanda	FI	0.8405 / 0.3918	0.07	0.00	DA	1.83	1.82	2.09	4.11	**RW**
Irlanda	IE	0.2126 / 0.3879	0.05	0.00	DA	2.27	1.93	15.26	3.85	**RW**
Italia	IT	0.3894 / 0.6164	0.96	0.00	DA	3.13	4.79	1.16	1.40	**MEAN**
Lituania	LT	0.4164 / 0.0982	0.24	0.00	DA	8.93	9.67	6.02	6.34	**MEAN**
Luxemburg	LU	0.0942 / 0.1353	0.60	0.00	DA	0.93	1.06	9.28	8.21	**ARDL**
Letonia	LV	0.6474 / 0.7603	0.09	0.00	DA	1.75	2.33	2.25	5.66	**ARDL**
Olanda	NL	0.4008 / 0.2439	0.69	0.00	DA	1.25	1.47	0.52	1.93	**MEAN**
Norvegia	NO	0.8703 / 0.5402	0.24	0.00	DA	4.09	6.51	3.72	1.06	**SEAS**
Polonia	PL	0.5373 / 0.7942	0.98	0.00	DA	1.55	2.59	5.60	3.69	**ARDL**
Portugalia	PT	0.6070 / 0.0471	0.04	0.00	NU	1.55	0.93	12.20	5.87	**RW**
Romania	RO	0.7926 / 0.9787	0.74	0.02	DA	0.91	1.55	3.67	2.44	**ARDL**
Suedia	SE	0.5813 / 0.7397	0.41	0.00	DA	3.49	3.53	8.86	1.35	**SEAS**
Slovenia	SI	0.3698 / 0.3821	0.30	0.00	DA	4.96	11.52	4.65	3.01	**SEAS**
Slovacia	SK	0.9775 / 0.9799	0.82	0.00	DA	3.31	3.38	12.14	2.11	**SEAS**
Franta	FR	0.4969 / 0.4860	0.82	0.00	NU	2.42	2.28	10.54	1.85	**SEAS**
Estonia	EE	0.7419 / 0.8827	0.21	0.00	DA	2.32	1.82	1.93	7.77	**RW**
Ungaria	HU	0.0894 / 0.1882	0.46	0.00	DA	3.14	3.01	5.78	1.40	**SEAS**

Sursa: Prelucrare proprie în R

În ansamblu, modelele ARDL sunt bine specificate: reziduurile sunt în marea majoritate a cazurilor necorelate (testul Breusch-Godfrey), iar ipoteza de homoscedasticitatea este în general acceptată (testul Breusch-Pagan). Normalitatea reziduurilor este respinsă doar într-un număr restrâns de cazuri, situații în care se recomandă inferență robustă sau prin bootstrap; pentru majoritatea țărilor, însă, ipoteza de normalitate nu este respinsă, ceea ce conferă credibilitate inferenței standard.

Aspectul cel mai delicat al diagnosticării îl constituie **stabilitatea recursivă a coeficienților**, evaluată prin testele CUSUM. Pentru cinci țări (Germania, Grecia, Spania, Franța, Portugalia), testul CUSUM recursiv semnalează o instabilitate latentă: traseul CUSUM depășește benzile critice în toate cele cinci cazuri, indicând instabilitate statistică semnificativă a coeficienților; momentul depășirii diferă între țări, reflectând rupturi structurale survenite în subperioade distincte ale intervalului 2008–2025.În aproape toate aceste cazuri, deriva este

localizată temporal în zona corespunzătoare crizei energetice din perioada 2020-2022, sugerând că relația dintre variabile a suferit o modificare în acest interval. Această observație nu invalidează modelele, dar constituie o rezervă importantă privind stabilitatea relațiilor estimate pe întreaga perioadă.

3.3.5. Performanța predictivă out-of-sample

Deși modelele ARDL au fost estimate în scop explicativ, performanța lor predictivă a fost evaluată comparativ cu trei modele de referință naive: mersul aleator, media și prognoza sezonieră. Rezultatele trebuie interpretate ținând cont de natura I(1) a consumului: pentru o serie integrată de ordinul întâi, este normal ca modelul ARDL să fie aproximativ la egalitate cu mersul aleator, acesta din urmă fiind un predictor dificil de depășit pentru astfel de serii. Într-adevăr, pentru opt țări mersul aleator obține cea mai bună acuratețe, iar pentru alte câteva modelul ARDL și mersul aleator sunt practic indistinctibile.

Cu toate acestea, pentru șapte țări (Cipru, Cehia, Spania, Luxemburg, Letonia, Polonia, România) **modelul ARDL depășește toate benchmark-urile**, inclusiv mersul aleator. Cazul României este remarcabil: deși relația de termen lung este respinsă, modelul ARDL obține o eroare procentuală out-of-sample de doar 0,91%, superioară tuturor alternativelor, cu o precizie deosebită la orizontul de o lună. Acest rezultat ilustrează o concluzie important: puterea predictivă a modelului provine în aceste cazuri din dinamica bogată pe termen scurt (impactul contemporan și întârziat al producției industriale și al temperaturii asupra consumului), independent de existența unei relații de cointegrare. Faptul că, pentru multe țări, benchmark-urile media și sezonierul obțin rezultate mult inferioare confirmă suplimentar caracterul nestaționar al consumului.

3.4. Sinteză

Tabelul nr. 3.7. Sinteza interpretativă a relației de termen lung, pe țări

Tara	Cod	Relatie TL	Sinteză interpretativă
Austria	AT	**NU**	Fără echilibru pe termen lung confirmat, termenul de corecție reflectă doar o reversiune slabă la medie, iar coeficienții de termen lung rămân fără conținut economic. Producția industrială intră cu semn negativ semnificativ, atribuit restructurării industriale.
Belgia	BE	**DA**	Relație de termen lung confirmată și ajustare validă către echilibru. Producția industrială apare cu semn negativ, explicat prin restructurarea industrială, iar reziduurile nenormale recomandă inferență robustă.
Bulgaria	BG	**DA**	Echilibru confirmat și ajustare validă, însă producția industrială intră cu semn negativ semnificativ, asociat transformărilor structurale din industrie. Reziduurile nenormale impun inferență robustă.

Cipru	CY	**DA**	Caz clar, cu relație de termen lung confirmată, ajustare validă și producție industrială cu semnul economic așteptat. Singura rezervă este abaterea reziduurilor de la normalitate.
Cehia	CZ	**NU**	Relația de termen lung este respinsă, deci termenul de corecție indică doar o reversiune slabă, iar coeficienții de termen lung nu sunt interpretabili. Producția industrială are semn negativ, asociat restructurării, iar reziduurile nenormale cer inferență robustă.
Germania	DE	**DA**	Echilibru confirmat și ajustare validă, cu producția industrială intrând cu semnul corect. Rezerva principală vine din testul de stabilitate, care semnalează o modificare a coeficienților în timp, legată de declinul consumului industrial german.
Danemarca	DK	**Inconcludent**	Cele două statistici bounds nu converg, deci echilibrul este incert și ajustarea se citește cu prudență. Producția industrială are semnul corect și este semnificativă, iar reziduurile nenormale cer inferență robustă.
Grecia	EL	**NU**	Relația de termen lung este respinsă, termenul de corecție reflectând doar o reversiune slabă. Producția industrială intră negativ (restructurare), iar instabilitatea coeficienților și nenormalitatea reziduurilor impun prudență sporită.
Spania	ES	**NU**	Echilibrul este respins, deci termenul de corecție indică doar o reversiune slabă și coeficienții de termen lung nu sunt interpretabili, în ciuda semnului corect al producției. Instabilitatea coeficienților și nenormalitatea, legate de șocul energetic recent, sunt rezerve suplimentare.
Finlanda	FI	**DA**	Relație de termen lung confirmată și ajustare validă. Producția industrială apare cu semn negativ, atribuit restructurării industriei energointensive, iar reziduurile nenormale cer inferență robustă.
Irlanda	IE	**Inconcludent**	Verdict bounds incert, cu cele două statistici în dezacord, deci ajustarea se interpretează cu rezervă. Producția industrială are semnul așteptat, consistent cu expansiunea economică recentă, iar reziduurile nenormale cer inferență robustă.
Italia	IT	**DA**	Echilibru confirmat și ajustare validă, cu producția industrială intrând cu semnul corect. Diagnosticele sunt în general curate, cu excepția abaterii reziduurilor de la normalitate.
Lituania	LT	**NU**	Relația de termen lung este respinsă, deci termenul de corecție reflectă o simplă reversiune slabă, iar coeficienții de termen lung nu sunt interpretabili. Producția industrială are semn negativ (restructurare), iar reziduurile nenormale cer inferență robustă.
Luxemburg	LU	**Divergent**	Statistica t confirmă relația, dar F rămâne inconcludentă, deci echilibrul este slab susținut și ajustarea rapidă se citește cu prudență. Producția industrială are semnul corect, iar reziduurile nenormale cer inferență robustă.
Letonia	LV	**DA**	Relație de termen lung confirmată și ajustare validă, cu producția industrială intrând cu semnul economic așteptat. Profil curat, singura rezervă fiind nenormalitatea reziduurilor.
Olanda	NL	**DA**	Echilibru confirmat și ajustare validă, producția industrială susținând consumul cu semnul corect. Diagnosticele sunt în mare parte curate, exceptând abaterea reziduurilor de la normalitate.

Norvegia	NO	**DA**	Relație de termen lung confirmată și ajustare validă. Producția industrială apare negativ, particularitate atribuită structurii economiei norvegiene, iar reziduurile nenormale cer inferență robustă.
Polonia	PL	**Inconcludent**	Cele două statistici bounds nu converg, deci echilibrul este incert și ajustarea se citește cu rezervă. Producția industrială are semn pozitiv semnificativ, consistent cu creșterea industrială recentă, iar reziduurile nenormale cer inferență robustă.
Portugalia	PT	**NU**	Relația de termen lung este respinsă, termenul de corecție indicând doar o reversiune slabă. Producția industrială intră negativ (restructurare), iar instabilitatea coeficienților și nenormalitatea reziduurilor impun prudență sporită.
Romania	RO	**NU**	Echilibrul este respins, iar termenul de corecție, deși semnificativ, este foarte mic și reflectă doar o reversiune slabă. Raportarea la un coeficient aproape nul face ca valorile de termen lung să fie lipsite de conținut economic, iar reziduurile nenormale cer inferență robustă.
Suedia	SE	**Inconcludent**	Verdict bounds incert, cu statisticile în dezacord, deci ajustarea se citește cu rezervă. Producția industrială intră cu semn negativ semnificativ, atribuit restructurării industriale suedeze, iar reziduurile nenormale cer inferență robustă.
Slovenia	SI	**DA**	Relație de termen lung confirmată și ajustare validă. Producția industrială apare cu semn negativ semnificativ, consistent cu declinul recent al industriei energointensive, iar reziduurile nenormale cer inferență robustă.
Slovacia	SK	**Inconcludent**	Cele două statistici bounds oferă verdicte diferite, deci echilibrul este incert și ajustarea se interpretează cu prudență. Producția industrială are semnul corect, iar reziduurile nenormale cer inferență robustă.
Franta	FR	**NU**	Relația de termen lung este respinsă, termenul de corecție reflectând doar o reversiune slabă. Producția industrială intră negativ (restructurare), iar instabilitatea coeficienților și nenormalitatea reziduurilor impun prudență sporită.
Estonia	EE	**DA**	Caz clar, cu relație de termen lung confirmată, ajustare validă și producție industrială cu semn pozitiv semnificativ. Singura rezervă este abaterea reziduurilor de la normalitate.
Ungaria	HU	**Inconcludent**	Verdict bounds incert, cu statisticile în dezacord, deci ajustarea se citește cu rezervă. Producția industrială are semn pozitiv semnificativ, consistent cu expansiunea industrială recentă, iar reziduurile nenormale cer inferență robustă.

Sursa: Prelucrare proprie în Excel

Analiza multivariată conduce la o imagine nuanțată a relației dintre consumul de electricitate, producția industrială și climă în spațiul european. Existența unei relații de echilibru pe termen lung nu este universal, ea este confirmată ferm pentru aproximativ 40% dintre țări, respinsă pentru aproape o treime, și incertă pentru restul. Acolo unde echilibrul există, viteza de ajustare și semnul determinanților variază semnificativ, reflectând structuri economice și energetice naționale eterogene. Două particularități transversale merită reținute: semnul frecvent negativ al producției industriale în relația de termen lung, atribuit restructurării industriale mai

degrabă decât unei relații economice inverse, și tensiunea dintre un termen de corecție semnificativ și un test bounds care respinge cointegrarea, situație în care coeficientul trebuie citit ca reversiune slabă, iar multiplicatorii de termen lung ca rezultate numerice lipsite de justificare economică. În plan predictiv, modelele ARDL se comportă conform așteptărilor pentru serii I(1), egalând sau depășind mersul aleator, performanța superioară din anumite cazuri provenind din dinamica pe termen scurt, iar nu din mecanismul de echilibru. Aceste rezultate subliniază că, deși metodologia a fost uniformă, relația fundamentală dintre activitatea economică, condițiile climatice și consumul de energie diferă substanțial de la o economie europeană la alta.

CONCLUZII

Lucrarea a analizat consumul de energie electrică în 26 de state europene, pe date lunare aferente perioadei 2008-2025, pe două direcții complementare, una univariată, dedicată modelării și previziunii fiecărei serii naționale, și una multivariată, dedicată relațiilor dintre consum, producția industrială și condițiile climatice.

Pe componenta univariată, rezultatele arată că niciuna dintre cele trei abordări considerate, modelul SARIMA construit cu ajutorul numeroaselor teste de staționaritate și autocorelație, modelul selectat automat și modelul de netezire exponențială, nu se dovedește superioară în mod universal, alegerea modelului final depinzând de specificul fiecărei serii. Cel mai instructiv tipar identificat este inversarea ierarhiei dintre evaluarea în interiorul eșantionului și cea în afara acestuia, observată în aproximativ o treime dintre cazuri, în care un model cu cel mai bun criteriu informațional se dovedea inferior în prognoza reală, semn clasic de supraajustare. Această constatare justifică decizia de a întemeia selecția finală pe performanța predictivă în afara eșantionului, iar nu exclusiv pe criteriile informaționale. Modelele de netezire exponențială s-au dovedit competitive pentru seriile cu amplitudine sezonieră mare sau variabilă, precum cele ale Danemarcei și Norvegiei, în timp ce un outlier negativ asociat restricțiilor din 2020 a generat, pentru câteva țări, o tensiune între adecvarea reziduurilor și acuratețea prognozei.

Pe componenta multivariată, analiza conduce la o imagine nuanțată. Existența unei relații de echilibru pe termen lung între consum, producția industrială și stresul termic nu este universală, ea fiind confirmată ferm pentru unsprezece țări, aproximativ 40 la sută din eșantion, respinsă pentru opt țări și incertă pentru restul. Țările cu relație confirmată se concentrează preponderent în nordul și centrul Europei, în timp ce spațiul mediteranean și Europa de est prezintă mai frecvent absența echilibrului sau rezultate inconcludente. Acolo unde echilibrul există, viteza de ajustare către acesta variază considerabil, de la valori moderate, în jur de 17 până la 20 la sută din dezechilibru corectat lunar, până la ajustări rapide de aproape 40 la sută, reflectând rigidități diferite ale piețelor energetice naționale.

Două particularități transversale merită reținute. Prima privește tensiunea dintre un termen de corecție a erorii semnificativ și un test bounds care respinge cointegrarea, situație în care coeficientul trebuie citit ca o simplă reversiune slabă la medie, iar nu ca un mecanism de corecție propriu-zis. A doua privește semnul frecvent negativ cu care producția industrială intră în relația de termen lung, chiar și în țări cu echilibru confirmat, fenomen atribuibil restructurării industriale și declinului ramurilor energointensive, iar nu unei relații economice inverse reale. Temperatura, surprinsă prin gradele-zile termice, intră în schimb cu semnul corect și cu magnitudine

substanțială în majoritatea țărilor cu echilibru confirmat, ceea ce o confirmă drept determinant climatic robust al consumului.

Diagnosticarea modelelor a arătat că, în ansamblu, acestea sunt bine specificate, reziduurile fiind în marea majoritate a cazurilor necorelate și homoscedastice. Testele de stabilitate au semnalat însă, pentru cinci țări, o instabilitate a coeficienților localizată temporal în zona crizei energetice din perioada 2020-2022, ceea ce constituie o rezervă privind stabilitatea relațiilor estimate pe întreaga perioadă. În plan predictiv, modelele autoregresive cu întârzieri distribuite s-au comportat conform așteptărilor pentru serii integrate de ordinul întâi, egalând sau depășind mersul aleator, performanța superioară din anumite cazuri provenind din dinamica bogată pe termen scurt, iar nu din mecanismul de echilibru, așa cum o ilustrează cazul României.

Concluzia de ansamblu a lucrării este aceea că, deși metodologia a fost aplicată uniform tuturor celor 26 de țări, relația fundamentală dintre activitatea economică, condițiile climatice și consumul de energie electrică diferă substanțial de la o economie europeană la alta. Această eterogenitate structurală constituie mesajul central al cercetării și are implicații practice directe, întrucât arată că previziunea consumului și fundamentarea politicilor energetice nu pot recurge la un model unic, ci necesită abordări adaptate fiecărei economii naționale.

Rezultatele trebuie interpretate ținând cont de câteva limite. Indicele producției industriale, folosit ca aproximare a activității economice, conține rupturi structurale care complică interpretarea relației de termen lung, iar perturbarea produsă de pandemie în anul 2020 a afectat o parte dintre serii. Configurația mixtă a ordinelor de integrare a impus utilizarea exclusivă a modelelor autoregresive cu întârzieri distribuite, iar caracterul dependent de perioadă al unora dintre relații, semnalat de testele de stabilitate, sugerează prudență în extrapolarea concluziilor.

Cercetarea poate fi extinsă în mai multe direcții. Utilizarea metodelor pe date de tip panel ar permite valorificarea simultană a informației din toate țările, iar modelele care permit schimbări de regim sau rupturi structurale ar putea surprinde mai bine modificările relațiilor în perioadele de criză. Includerea unor determinanți suplimentari, precum prețul energiei, ponderea surselor regenerabile sau venitul, precum și tratarea explicit neliniară a efectului temperaturii, ar putea îmbogăți înțelegerea mecanismelor analizate.

În ansamblu, lucrarea contribuie la literatura de specialitate printr-o analiză sistematică, comparativă și reproductibilă a consumului de energie electrică pe un eșantion amplu de state europene și oferă o bază pentru cercetări viitoare asupra determinanților consumului energetic în spațiul european.

BIBLIOGRAFIE

Anghelache, C. și Manole, A., 2012. Seriile dinamice / cronologice (de timp). Revista Română de Statistică, (10), pp.68-77.

Anghelache, C., Anghelache, G.V. și Bârsan, O., 2019. Modelul Tramo-Seats utilizat în analiza seriilor dinamice. Revista Română de Statistică - Supliment, (6), pp.3-27.

Bashiri Behmiri, N., Fezzi, C. and Ravazzolo, F., 2023. Incorporating air temperature into mid-term electricity load forecasting models using time-series regressions and neural networks. Energy, 278, 127831. DOI: 10.1016/j.energy.2023.127831

Bianco, V., Marchitto, A., Scarpa, F. and Tagliafico, L.A., 2020. Forecasting Energy Consumption in the EU Residential Sector. International Journal of Environmental Research and Public Health, 17(7), 2259. DOI: 10.3390/ijerph17072259

Colonescu, C., 2016. Principles of Econometrics with R. [online] Disponibil la: <https://bookdown.org/ccolonescu/RPoE4\> [Accesat 10 mai 2026].

Drăgușin, L.M., 2013. Metode econometrice în Conturile Naționale Trimestriale din România. Revista Română de Statistică, (4), pp.5-16.

Eurostat, 2025. Cooling and heating degree days by country - monthly data [nrg_chdd_m]. [online] Luxemburg: Eurostat. Disponibil la: <https://ec.europa.eu/eurostat/databrowser/view/nrg_chdd_m\> [Accesat 25 martie 2026].

Eurostat, 2025. Production in industry - monthly data [sts_inpr_m]. [online] Luxemburg: Eurostat. Disponibil la: <https://ec.europa.eu/eurostat/databrowser/view/sts_inpr_m\> [Accesat 25 martie 2026].

Eurostat, 2025. Supply, transformation and consumption of electricity - monthly data [nrg_cb_em]. [online] Luxemburg: Eurostat. Disponibil la: <https://ec.europa.eu/eurostat/databrowser/view/nrg_cb_em\> [Accesat 25 martie 2026].

Fezzi, C. and Fanghella, V., 2021. Tracking GDP in real-time using electricity market data: Insights from the first wave of COVID-19 across Europe. European Economic Review, 139, 103907. DOI: 10.1016/j.euroecorev.2021.103907

Halbrügge, S., Schott, P., Weibelzahl, M., Buhl, H.U., Fridgen, G. and Schöpf, M., 2021. How did the German and other European electricity systems react to the COVID-19 pandemic? Applied Energy, 285, 116370. DOI: 10.1016/j.apenergy.2020.116370

Hyndman, R.J. and Athanasopoulos, G., 2021. Forecasting: Principles and Practice. 3rd ed. Melbourne: OTexts. [online] Disponibil la: <https://otexts.com/fpp3\> [Accesat 5 mai 2026].

Litavcová, E. and Chovancová, J., 2021. Economic Development, CO2 Emissions and Energy Use Nexus-Evidence from the Danube Region Countries. Energies, 14(11), 3165. DOI: 10.3390/en14113165

López Prol, J. and Oviedo, S., 2020. Impact of COVID-19 Measures on Short-Term Electricity Consumption in the Most Affected EU Countries and USA States. iScience, 23(10), 101639. DOI: 10.1016/j.isci.2020.101639

Marinaș, M.-C., Dinu, M., Socol, A.-G. and Socol, C., 2018. Renewable energy consumption and economic growth. Causality relationship in Central and Eastern European countries. PLOS ONE, 13(10), e0202951. DOI: 10.1371/journal.pone.0202951

Marra, A. and Colantonio, E., 2022. The institutional and socio-technical determinants of renewable energy production in the EU: implications for policy. Journal of Industrial and Business Economics, 49, pp.267-299.

Pablo-Romero, M.P., Sánchez-Braza, A. and González-Jara, D., 2023. Economic growth and global warming effects on electricity consumption in Spain: a sectoral study. Environmental Science and Pollution Research, 30, pp.43096-43112.

Pavlova, O., Pavlov, K., Liashenko, O., Jamróz, A. and Kopeć, S., 2025. Gas in Transition: An ARDL Analysis of Economic and Fuel Drivers in the European Union. Energies, 18(14), 3876. DOI: 10.3390/en18143876

Pełka, P., 2023. Analysis and Forecasting of Monthly Electricity Demand Time Series Using Pattern-Based Statistical Methods. Energies, 16(2), 827. DOI: 10.3390/en16020827

Román-Collado, R., Colinet-Carmona, M.J. and Fárez-Plasencia, M.I., 2023. Is temperature change a key driver of the regional differences in electricity consumption of the economic sectors in Spain (2000-2016)? Environmental Science and Pollution Research, 30, pp.81131-81150.

Şahin, U., Ballı, S. and Chen, Y., 2021. Forecasting seasonal electricity generation in European countries under Covid-19-induced lockdown using fractional grey prediction models and machine learning methods. Applied Energy, 302, 117540. DOI: 10.1016/j.apenergy.2021.117540

Sankaran, A., Kumar, S., Arjun, K. and Das, M., 2019. Estimating the causal relationship between electricity consumption and industrial output: ARDL bounds and Toda-Yamamoto approaches for ten late industrialized countries. Heliyon, 5(6), e01904. DOI: 10.1016/j.heliyon.2019.e01904

Shrestha, M.B. și Bhatta, G.R., 2018. Selecting Appropriate Methodological Framework for Time Series Data Analysis. The Journal of Finance and Data Science, 4(2), pp.71-89.

Stanciu, C.V. and Mitu, N.E., 2025. Price Behavior and Market Integration in European Union Electricity Markets: A VECM Analysis. Energies, 18(4), 770. DOI: 10.3390/en18040770